



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده مهندسی پزشکی

گزارش پروژه‌ی درس سیستم‌های تصویرگر پزشکی

موضوع پروژه:

پیاده‌سازی یک الگوریتم بر مبنای Compressed Sensing روی تصاویر
زانو و مغز (پایگاه fastMRI)

استاد درس:

دکتر مولایی

تهیه و تنظیم:

سپهر کلانکی (۴۰۴۱۳۳۰۱۲)

اسفند ماه ۱۴۰۴

چکیده

در این گزارش ابتدا به معرفی روش compressed sensing اهمیت آن در بازسازی تصاویر تشدید مغناطیسی می‌پردازیم. سپس مقاله‌ی انتخاب شده برای پروژه را قسمت به قسمت توضیح داده و نتایج پیاده‌سازی هر بخش را شرح می‌دهیم. در نهایت، به مقایسه نتایج خود با نتایج مقاله پرداخته می‌شود.

واژه‌های کلیدی:

Compressed Sensing، تصویربرداری تشدید مغناطیسی (MRI)، پایگاه داده‌ی fastMRI، بازسازی تصاویر MRI

صفحه	فهرست مطالب
۱	چکیده.....
۷	فصل اول.....
۷	مقدمه.....
۸	۱-۱- یکی از مهم‌ترین چالش‌های MRI.....
۸	۱-۱-۱- مشکلات بالینی و بیمار محور.....
۹	۱-۱-۲- مشکلات سخت‌افزاری و هزینه‌ای.....
۹	۱-۱-۳- مشکلات فنی و کیفیت تصویر.....
۱۰	۱-۲- چگونه این چالش را برطرف کنیم؟.....
۱۰	۱-۲-۱- اخذ تصویر موازی (PI).....
۱۱	۱-۲-۲- روش‌های مبتنی بر هوش مصنوعی (AI).....
۱۲	۱-۲-۳- اسپین‌اکوی سریع (TSE یا FSE).....
۱۲	۱-۲-۴- حس‌گری فشرده (CS).....
۱۴	فصل دوم.....
۱۴	روش Compressed Sensing.....
۱۵	۱-۲- فشرده‌سازی.....
۱۷	۲-۲- تُنکی (Sparsity).....
۱۹	۱-۲-۲- denoise کردن تصاویر Sparse با تبدیل wavelet.....
۲۱	۳-۲- کم‌نمونه برداری (Undersampling).....
۲۱	۱-۳-۲- نمونه‌برداری با نرخ نایکویست.....
۲۲	۲-۳-۲- نمونه‌برداری یکنواخت (کمتر از نرخ نایکویست).....
۲۳	۳-۳-۲- نمونه‌برداری تصادفی (کمتر از نرخ نایکویست).....
۲۴	۴-۳-۲- نمونه‌برداری دایروی (کمتر از نرخ نایکویست).....
۲۵	۴-۲- روش Compressed Sensing.....
۲۵	۱-۴-۲- مثال بازسازی سیگنال با روش CS.....
۲۶	۲-۴-۲- sparsity در روش CS.....
۲۷	۳-۴-۲- مثال بازسازی تصویر با روش CS.....
۲۸	۴-۴-۲- CS، مسئله‌ی بهینه‌سازی؟.....
۲۹	۵-۴-۲- الزامات دنیای واقعی روش CS.....
۳۰	۵-۲- جمع‌بندی.....
۳۱	فصل سوم.....

۳۱	توضیح و پیاده‌سازی مقاله
۳۲	۱-۳- معرفی مقاله
۳۳	۲-۳- چکیده
۳۴	۳-۳- مقدمه
۳۴	۱-۳-۳- معرفی روش CS
۳۵	۲-۳-۳- معرفی برخی روش‌های دیگر بازسازی تصاویر MRI
۳۵	۳-۳-۳- الگوریتم SL0
۳۶	۴-۳-۳- نوآوری مقاله
۳۷	۴-۳- روش انجام پژوهش
۳۷	۱-۴-۳- الگوریتم SL0
۳۹	۲-۴-۳- ایده‌ی اصلی
۴۰	۱-۲-۴-۳- شکستن الگوریتم ISRSLO به دو مسئله‌ی مجزا
۴۱	۳-۴-۳- denoise کردن
۴۲	۱-۳-۴-۳- BM3D denoiser [۱۰]
۴۴	۲-۳-۴-۳- WIENER denoiser [۱۱]
۴۵	۴-۴-۳- تیزسازی
۴۶	۵-۴-۳- ویژگی‌های یک تبدیل unitary [۱۲, ۱۳]
۴۷	۶-۴-۳- اعمال کردن تیزسازی و denoising
۴۸	۷-۴-۳- کاهش و نگاشت گرادیان
۵۲	۸-۴-۳- الگوریتم ISRSLO
۵۲	۱-۸-۴-۳- حلقه‌ی خارجی
۵۳	۲-۸-۴-۳- حلقه‌ی داخلی
۵۴	۹-۴-۳- تحلیل و اثبات هم‌گرایی
۵۵	۱۰-۴-۳- ماسک‌های نمونه‌برداری
۵۶	۱-۱۰-۴-۳- پیاده‌سازی ماسک‌ها در پایتون
۶۵	۵-۳- معیارهای ارزیابی روش
۶۵	۱-۵-۳- PSNR
۶۵	۲-۵-۳- HFEN
۶۶	۳-۵-۳- SSIM
۶۶	۶-۳- دادگان پژوهش
۶۶	۱-۶-۳- تصاویر زانو
۶۹	۲-۶-۳- تصاویر مغز
۶۹	۱-۲-۶-۳- کنتراست‌های مختلف
۷۰	۷-۳- نتایج مقاله
۷۰	۱-۷-۳- اثر ماسک‌های نمونه‌برداری
۷۰	۲-۷-۳- نتایج بازسازی تصاویر زانو

۷۱	۳-۷-۳- نتایج بازسازی تصاویر مغز
۷۱	۳-۷-۴- مقایسه‌ی زمان محاسبات روش‌های مختلف
۷۲	۳-۸- نتایج پیاده‌سازی من
۷۲	۳-۸-۱- نتایج بازسازی تصاویر زانو
۷۳	۳-۸-۱-۱- یک نمونه تصویر بازسازی شده
۷۴	۳-۸-۲- نتایج بازسازی تصاویر مغز
۷۴	۳-۸-۲-۱- یک نمونه تصویر بازسازی شده
۷۵	۳-۹- جمع‌بندی
۷۷	فصل چهارم
۷۷	نتیجه‌گیری و پیشنهادات
۷۸	۴-۱- نتیجه‌گیری و سخن پایانی
۷۹	منابع و مراجع

فهرست اشکال

- شکل ۱-۱- شماتیک اخذ تصویر به روش PI با دو کوئل RF (شکل چپ: پوشش FOV کامل توسط هر کوئل) (شکل راست: پوشش نصف فضای k توسط هر کوئل) [۶] ۱۱
- شکل ۲-۱- نمونه‌ای از بازسازی تصویر به روش PI [۶] ۱۱
- شکل ۳-۱- نمونه‌ای از سکانس حالت اسپین اکوی نرمال در مقابل اسپین اکوی سریع در MRI [۸] ۱۲
- شکل ۱-۲- شماتیکی از نمونه‌برداری از فضای k ، اخذ تصویر و فشرده‌سازی آن ۱۶
- شکل ۲-۲- شماتیکی از بازسازی یک تصویر MRI به کمک روش CS ۱۷
- شکل ۳-۲- شماتیکی از تصاویر و سیگنال‌های sparse و غیر sparse ۱۸
- شکل ۴-۲- شماتیکی از یک تصویر غیر sparse و لبه‌های sparse آن ۱۸
- شکل ۵-۲- شماتیکی از یک تصویر MRI مغزی در حوزه‌ی مکان و حوزه‌ی تبدیل wavelet ۱۹
- شکل ۶-۲- ضرایب denoise شده‌ی حوزه‌ی wavelet به همراه تصویر MRI مغز حاصل شده از گرفتن عکس تبدیل wavelet ۲۰
- شکل ۷-۲- مقایسه‌ی تصویر MRI اولیه و تصویر denoise شده به کمک تبدیل wavelet ۲۱
- شکل ۸-۲- نمونه‌برداری از فضای k ی یک تصویر با نرخ نایکویست و بازسازی تصویر با گرفتن عکس تبدیل فوریه ۲۲
- شکل ۹-۲- نمونه‌برداری یکنواخت فضای k با نرخ کوچک‌تر از نایکویست و نمایش تصویر بازسازی شده ۲۲
- شکل ۱۰-۲- نمونه‌برداری تصادفی از فضای k با نرخ کمتر از نایکویست و نمایش تصویر بازسازی شده ۲۳
- شکل ۱۱-۲- نمونه‌برداری تصادفی با چگالی متغیر از فضای k با نرخ کمتر از نایکویست و نمایش تصویر بازسازی شده ۲۴
- شکل ۱۲-۲- نمونه‌برداری دایروی از فضای k با نرخ کمتر از نایکویست و نمایش تصویر بازسازی شده ۲۴
- شکل ۱۳-۲- مثالی ساده از روش CS برای یک سیگنال تک بعدی ۲۶
- شکل ۱۴-۲- حیطه‌های سیگنال، sparse و نمونه‌برداری در روش CS ۲۷
- شکل ۱۳-۲- مثالی از روش CS برای یک تصویر MRI مغز ۲۸
- شکل ۱۴-۲- نمونه‌ای از سیگنال محدب و غیر محدب [۹] ۲۹
- شکل ۱-۴- تصویر صفحه‌ی اول مقاله‌ی انتخاب شده ۳۳
- شکل ۲-۴- تابع SL0 برای مقادیر مختلف σ ۳۸
- شکل ۳-۴- بلوک دیاگرام نحوه‌ی عملکرد BM3D denoiser [۱۰] ۴۳
- شکل ۴-۴- بلوک دیاگرام شماتیک روش ISRSLO ۴۷
- شکل ۴-۴- مراحل کامل الگوریتم ISRSLO ۵۴
- شکل ۵-۴- یک نمونه تصویر MRI زانو و مغز به همراه فضای k ی کامل آن ۵۶

شکل ۴-۶- نتیجه‌ی اعمال ماسک مربعی ۱۰ درصد روی یک نمونه تصویر MRI زانو و مغز.....	۵۷
شکل ۴-۷- نتیجه‌ی اعمال ماسک کارت‌زین افقی ۱۰ درصد روی یک نمونه تصویر MRI زانو و مغز.....	۵۸
شکل ۴-۸- نتیجه‌ی اعمال ماسک کارت‌زین عمودی ۱۰ درصد روی یک نمونه تصویر MRI زانو و مغز.....	۵۹
شکل ۴-۹- نتیجه‌ی اعمال ماسک شبه دایروی ۱۰ درصد روی یک نمونه تصویر MRI زانو و مغز.....	۶۰
شکل ۴-۱۰- نتیجه‌ی اعمال ماسک شبه دایروی ۱۰ درصد روی یک نمونه تصویر MRI زانو و مغز.....	۶۱
شکل ۴-۱۱- نتیجه‌ی اعمال ماسک تصادفی ۱۰ درصد روی یک نمونه تصویر MRI زانو و مغز.....	۶۲
شکل ۴-۱۲- نتیجه‌ی اعمال ماسک تصادفی با چگالی متغیر ۱۰ درصد روی یک نمونه تصویر MRI زانو و مغز.....	۶۳
شکل ۴-۱۳- ماسک شبه دایروی با نرخ‌های نمونه‌برداری مختلف.....	۶۴
شکل ۴-۱۴- ایمیل حاوی لینک دانلود داده‌های زانو پایگاه fastMRI.....	۶۷
شکل ۴-۱۵- فضای خام یک تصویر زانو از پایگاه fastMRI.....	۶۸
شکل ۴-۱۶- مقایسه‌ی دقت روش ISRL0 برای ماسک‌های مختلف.....	۷۰
شکل ۴-۱۷- مقایسه‌ی دقت روش ISRL0 برای تصاویر زانو و ماسک‌های مختلف و نرخ نمونه‌برداری‌های مختلف.....	۷۱
شکل ۴-۱۸- مقایسه‌ی دقت روش ISRL0 برای تصاویر مغز و ماسک‌های مختلف و نرخ نمونه‌برداری‌های مختلف.....	۷۱
شکل ۴-۱۹- مقایسه‌ی زمان محاسباتی روش ISRL0 با سایر روش‌های رایج که در مقاله صرفاً در حد یک جمله به آن‌ها اشاره شده بود.....	۷۲
شکل ۴-۲۰- نتایج پیاده‌سازی بنده برای ۱۹۹ تصویر زانو با استفاده از روش‌های مختلف (SL0, zero-filling, ISRL0-BM3D, Wiener-ISRL0) و نرخ نمونه‌برداری‌های مختلف.....	۷۳
شکل ۴-۲۱- مقایسه‌ی بازسازی یک نمونه تصویر زانو با استفاده از روش‌های مختلف (SL0, zero-filling, ISRL0-BM3D, Wiener-ISRL0) و نرخ نمونه‌برداری ۲۰ درصد و ماسک شبه دایروی.....	۷۳
شکل ۴-۲۲- نتایج پیاده‌سازی بنده برای ۱۰۶ تصویر مغز با استفاده از روش‌های مختلف (SL0, zero-filling, ISRL0-BM3D, Wiener-ISRL0) و نرخ نمونه‌برداری‌های مختلف.....	۷۴
شکل ۴-۲۳- مقایسه‌ی بازسازی یک نمونه تصویر مغز با استفاده از روش‌های مختلف (SL0, zero-filling, ISRL0-BM3D, Wiener-ISRL0) و نرخ نمونه‌برداری ۲۰ درصد و ماسک شبه دایروی.....	۷۵
شکل ۴-۲۴- مقایسه‌ی میانگین دقت روش بنده با بهترین نتایج مقاله برای تصاویر زانو.....	۷۵
شکل ۴-۲۵- مقایسه‌ی میانگین دقت روش بنده با بهترین نتایج مقاله برای تصاویر مغز.....	۷۵

فصل اول

مقدمه

تصویربرداری تشدید مغناطیسی^۱ (MRI) طی دهه‌های اخیر به یکی از پیشرفته‌ترین روش‌های تشخیص و بررسی بیماری‌های مختلف تبدیل شده است؛ روشی غیرتهاجمی که با بهره‌گیری از امواج فرکانس رادیویی و میدان مغناطیسی، ساختار، عملکرد، متابولیسم و مورفولوژی بافت‌های نرم را با کنتراست عالی و بدون استفاده از اشعه‌های مضر و یونیزه کننده مانند X-ray ارزیابی می‌کند [۱، ۲].

۱-۱- یکی از مهم‌ترین چالش‌های MRI

MRI به طور گسترده برای تصویربرداری دقیق از اندام‌های مختلف استفاده می‌شود، اما برخلاف روش‌های بالینی دیگر مانند توموگرافی کامپیوتری^۲ (CT) یا سونوگرافی، با چالش اساسی زمان طولانی اخذ تصویر (پر کردن فضای k یا فرکانس) مواجه است [۱]. این طولانی بودن زمان تصویربرداری، مشکلات زیر را به ارمغان می‌آورد:

۱-۱-۱- مشکلات بالینی و بیمارمحور

ناراحتی بیمار: بیمار حین اخذ تصویر باید بی‌حرکت بماند تا از آرتیفکت‌های حرکتی جلوگیری شود. بی‌حرکتی طولانی در تونل باریک و سرد دستگاه MRI باعث اضطراب، خستگی و تعریق می‌شود [۳].

حرکت ناخواسته: حتی اگر میزان تحمل بیمار خیلی بالا باشد، باز هم ممکن است به صورت ناخواسته حرکت کند (سرفه، بلع، خمیازه، عطسه). همچنین در صورت بی‌حرکتی کامل، بازهم ارگان‌های داخلی وی حرکت می‌کنند مانند ریه‌ها (تنفس) و قلب (پمپاژ کردن خون) [۳].

¹ Magnetic Resonance Imaging

² Computed Tomography

۱-۲-۱- مشکلات سخت‌افزاری و هزینه‌ای

افزایش هزینه و کاهش بازدهی: با افزایش زمان اخذ تصویر، صف‌های انتظار طولانی برای اخذ تصویر ایجاد می‌شوند. همچنین می‌دانیم که روشن نگه داشتن دستگاه MRI، نیازمند ثابت نگه داشتن میدان بزرگ B0 (در حد چند تسلا) می‌باشد که هم سخت و هم هزینه‌بر است.

تاخیر در انجام اسکن‌ها [۴]: طبق ژورنال آمریکایی کالج رادیولوژی^۳، در مطالعه‌ای بر روی بیش از ۳۴ هزار اسکن MRI در ۹ مرکز تصویربرداری در شهر اموری (Emory) در آمریکا، ۱۷ درصد از اسکن‌ها با تاخیر انجام شدند که دلایل تاخیر به شرح زیر بودند:

- ۵۳٪: حرکت بیمار

- ۳۱٪: کلاستروفوبیا (ترس از فضای بسته)

- ۱۹٪: دیر رسیدن بیمار

این گزارش توسط دکتر گلاره صدیق، یک رادیولوژیست در دانشگاه اموری آمریکا تهیه شده است.

۱-۳-۱- مشکلات فنی و کیفیت تصویر

بخاطر حرکت‌های ناخواسته‌ای که توضیح داده‌شد، آرتیفکت‌های حرکتی به تصویر اضافه می‌شوند. یعنی یک قسمت مشخص از بافت، در این لحظه در یک موقعیت قرار دارد و در لحظه‌ی بعدی موقعیتش تغییر می‌کند. این قضیه باعث تار شدن تصویر می‌شود که در مواقعی ممکن است تصاویر را غیر قابل تفسیر بکنند. همچنین آرتیفکت حرکتی نوعی نویز محسوب می‌شود و باعث کاهش نسبت سیگنال به نویز^۴ (SNR) تصویر می‌شود [۳].

در نتیجه کوتاه‌تر شدن زمان اخذ تصویر و در عین حال عدم کاهش کیفیت تصویر اخذ شده، می‌تواند بسیار مفید باشد.

³ Journal of the American College of Radiology

⁴ Signal-to-Noise Ratio


۱-۲- چگونه این چالش را برطرف کنیم؟

روش‌های متعددی برای کاهش زمان اخذ تصویر MRI وجود دارند که معمولاً به دسته‌های نرم‌افزاری و سخت‌افزاری تبدیل می‌شوند.

۱-۲-۱- اخذ تصویر موازی^۵ (PI)

PI روشی سخت‌افزاری برای تسریع زمان اخذ تصویر MRI است که با استفاده از آرایه‌ای از کوئل‌های گیرنده با حساسیت فضایی متفاوت، بخشی از اطلاعات مکانی را از طریق پروفایل کوئل‌ها تأمین می‌کند و در نتیجه می‌توان خطوط k -space کمتری را با هر کوئل نمونه‌برداری کرد. محدودیت اصلی PI کاهش SNR، افزایش نویز و وابستگی عملکرد به تعداد و چینش کوئل‌ها است. به همین دلیل در واقعیت، این روش با روش‌های بازسازی نرم‌افزاری ترکیب می‌شود تا هم سرعت و هم کیفیت تصویر حفظ شود [۵].


مطابق شکل ۱-۱، اگر بخواهیم برای مثال با دو کوئل موازی اخذ تصویر کنیم، می‌توانیم با هر کوئل، فضای k را به صورت کامل پوشش دهیم. به این ترتیب، تصویری با رزولوشن و SNR بیشتر حاصل می‌شود (شکل سمت چپ) ولی تغییری در اخذ سرعت تصویربرداری رخ نمی‌دهد. ولی اگر هر کوئل، فقط نصف فضای k را پر کند (مثلاً به صورت خطوط موازی یکی در میان)، زمان اخذ تصویر نصف می‌شود. اما این حالت باعث بروز تاشدگی (Folding) در تصویر می‌شود که نیازمند بازسازی است (شکل ۱-۲) [۶].



⁵ Compressed Sensing

شکل ۱-۱- شماتیک اخذ تصویر به روش PI با دو کوئل RF (شکل چپ: پوشش FOV کامل توسط هر کوئل) (شکل

راست: پوشش نصف فضای k توسط هر کوئل) [۶]



شکل ۱-۲- نمونه‌ای از بازسازی تصویر به روش PI [۶]

به این ترتیب، فاکتور شتاب^۶ (AF) افزایش پیدا می‌کند این فاکتور نشان‌دهنده میزان تسریع اسکن با رد کردن خطوط k -space است و معمولاً بین ۲ تا ۶ قرار می‌گیرد؛ این فاکتور نسبت خطوط کاملاً نمونه‌برداری‌شده به خطوط اکتساب‌شده را نشان می‌دهد. AF بالاتر زمان اسکن را کاهش می‌دهد، اما SNR را پایین آورده و نویز را افزایش می‌دهد.

۱-۲-۲- روش‌های مبتنی بر هوش مصنوعی (AI)

هوش مصنوعی و Deep یادگیری عمیق انقلابی در بازسازی MRI ایجاد کرده و زمان اسکن را ۵۰ الی ۸۰ درصد کاهش داده‌اند. شبکه‌های عصبی مختلف مثل CNN و U-NET، داده‌های کم‌نمونه‌برداری شده‌ی فضای k را مستقیماً به تصاویر با کیفیت و رزولوشن بالا تبدیل می‌کنند. الگوریتم‌های FDA-approved مانند Compressed SENSE AI یا NVIDIA Clara، می‌توانند AF بین ۵ تا ۱۰ را


⁶ Acceleration Factor

فراهم کنند و آرتیفکتهای حرکتی را نیز حذف می‌نمایند. علارغم مزایای روش‌های مبتنی بر AI، این روش‌ها نیاز به داده‌های آموزشی بزرگ دارد و با خطر بیش‌برازش (Over fitting) مواجه هستند [۷].

۳-۲-۱- اسپین‌اکوی سریع^۷ (TSE یا FSE)

TSE/FSE نسخه بهینه‌شده‌ی اسپین‌اکو است که با هر پالس RF ۹۰ درجه، چندین خط k-space را پر می‌کند و زمان اخذ تصویر را ۵-۱۰ برابر نسبت به اسپین‌اکوی کلاسیک کاهش می‌دهد. از معایب این روش می‌توان به تار شدگی، بار محاسباتی بازسازی بالا، آرتیفکتهای ناشی از شیف‌ت شیمیایی و حساس بودن به ناهمگنی میدان B1 اشاره کرد.

شکل ۳-۱ نمونه‌ای از سکانس پالس‌های حالت نرمال اسپین‌اکو در مقابل حالت اسپین‌اکوی سریع را نشان می‌دهد [۸].



شکل ۳-۱- نمونه‌ای از سکانس حالت اسپین‌اکوی نرمال در مقابل اسپین‌اکوی سریع در MRI [۸]

۳-۲-۲- حس‌گری فشرده^۸ (CS)

CS روشی ریاضی است که یک سیگنال یا تصویر را از دادگان کم‌نمونه برداری شده (نرخ نمونه‌برداری کمتر از نایکویست) بازسازی می‌کند. این روش برای تسریع MRI به صورت گسترده استفاده می‌شود، زیرا

⁷ Turbo Spin-Echo (TSE) / Fast Spin-Echo (FSE)

⁸ Compressed Sensing

زمان طولانی اسکن به دلیل پر کردن فضای k با نرخ نایکویست را بدون افت کیفیت تصویر، کاهش می‌دهد. لذا عمل فشرده‌سازی به معنی دور ریختن نمونه‌های فرکانسی اضافه و نگه داشتن نمونه‌های اصلی و مهم می‌باشد.

در فصل بعدی به بررسی دقیق‌تر این روش پرداخته می‌شود.

فصل دوم

روش Compressed Sensing


توجه: شکل‌های ۱-۲، تا ۱۳-۲ از اسلایدهای دکتر مایکل لاستیگ^۱، عضو هیئت علمی دانشگاه UC Berkeley آمریکا برگرفته شده است. وبسایت شخصی ایشان که پر از محتواهای آموزنده درباره‌ی روش compressed sensing در MRI می‌باشد، از این [لینک](#) قابل دسترسی است. مباحث این فصل به صورت ترکیبی از اسلایدها و یکی از سخنرانی‌های دکتر مایکل لاستیگ ([لینک](#)) و همچنین از یکی از مقاله‌های ریویویی حوزه‌ی CS با عنوان Compressed Sensing MRI: A Review آورده شده است.

۲-۱- فشرده‌سازی

فشرده‌سازی تصاویر به روش سنتی، پس از اخذ کامل تصویر انجام می‌شود و معمولاً شامل تبدیل موجک^۲ تصویر است. هدف صرفه‌جویی در ذخیره‌سازی و تسهیل انتقال داده‌هاست. داده‌های فشرده‌شده فقط شامل مهم‌ترین ضرایب هستند که بازسازی تقریباً بی‌نقص و نزدیک به داده اصلی را ممکن می‌سازند [۲]. شکل ۱-۲، شماتیک ساده‌ای از فشرده‌سازی سنتی یک تصویر مغزی یعنی پر کردن کامل فضای k با نرخ نایکویست و فشرده کردن آن را نشان می‌دهد.


^۱ Michael Lustig

^۲ Wavelet



شکل ۱-۲- شماتیکی از نمونه‌برداری از فضای k ، اخذ تصویر و فشرده‌سازی آن

شکل ۲-۲ در ادامه‌ی شکل ۱-۲ می‌باشد و شماتیک ساده‌ای از فرایند CS را نشان می‌دهد. درواقع به جای پر کردن کامل فضای k و سپس فشرده‌سازی آن، در همان ابتدای اخذ تصویر، تعداد کمتری از داده‌های فضای k اخذ می‌شود که به آن، عمل sensing گفته می‌شود. سپس از روی این دادگان، عمل بازسازی تصویر انجام می‌شود. این‌گونه زمان اخذ تصویر به طرز قابل توجهی کاهش پیدا می‌کند. این همان روش CS می‌باشد. یعنی بازسازی تصویر با استفاده از بخشی از ضرایب فضای k ی آن.




شکل ۲-۲- شماتیکی از بازسازی یک تصویر *MRI* به کمک روش *CS*

یک مفهوم بسیار مهم در *CS*، تُنکی (*Sparsity*) می‌باشد که در ادامه به توضیح آن پرداخته می‌شود.

۲-۲- تُنکی (*Sparsity*)

به یک بردار *sparse* گفته می‌شود اگر اکثر ضرایب آن صفر باشند و تنها ضرایب اندکی، حاوی کل اطلاعات این بردار باشند. از دیدگاه پردازش سیگنالی، سیگنال *sparse* انرژی‌اش را در تعداد اندکی از اندازه‌گیری‌ها متمرکز کرده و بقیه‌ی ضرایب، دارای انرژی صفر یا ناچیز هستند. برای مثال یک سیگنال سینوسی با فرکانس ۱۰ هرتز، در حوزه‌ی زمان، *sparse* محسوب نمی‌شود اما در حوزه‌ی فرکانس تنها یک پیک در فرکانس ۱۰ هرتز دارد و *sparse* محسوب می‌شود [۲]. خوش‌بختانه اکثر تصاویر *MRI* در بعضی از حوزه‌ها مثل حوزه‌ی *wavelet* خاصیت *sparsity* دارند و از همین خاصیتشان برای روش *CS* استفاده می‌شود.

شکل ۲-۳، یک نمونه سیگنال و تصویر *sparse* (سمت چپ)، یک نمونه سیگنال و تصویر غیر *sparse* یا نویزی (سمت راست) به همراه مجموع این دو (در وسط) را نشان می‌دهد. تصاویر در حوزه‌ی مکان هستند ولی سیگنال‌ها در حوزه‌ی فرکانس.



شکل ۲-۳- شماتیکی از تصاویر و سیگنال‌های *sparse* و غیر *sparse*

با توجه به شکل ۲-۳ مشاهده می‌شود که می‌توان سیگنال *sparse* در وسط را به کمک آستانه‌گذاری از سیگنال نویزی جدا کرد.

شکل ۲-۴، یک نمونه تصویر را نشان می‌دهد که در حوزه‌ی مکان غیر *sparse* است اما مولفه‌های فرکانس بالای آن (لبه‌های تصویر) *sparse* هستند. این لبه‌های تصویر می‌توانند بعد از اعمال تبدیل *wavelet* یا اعمال یک فیلتر بالاگذر بدست بیایند.




شکل ۲-۴- شماتیکی از یک تصویر غیر *sparse* و لبه‌های *sparse* آن

۲-۱-۲- denoise کردن تصاویر Sparse با تبدیل wavelet

sparsity را می‌توان به قابلیت فشرده‌سازی (compressibility) گسترش داد، جایی که ضرایب مهم برای بازسازی سیگنال اصلی حفظ می‌شوند. آستانه در ناحیه‌ای اعمال می‌شود که دامنه ضرایب (مرتب‌شده نزولی) افت شدیدی دارد (مشابه شکل ۲-۳). این آستانه تعداد ضرایب مورد نیاز برای بازسازی را تعیین می‌کند و مرز بین ضرایب مهم و کم‌اهمیت را نشان می‌دهد (مشابه فرکانس قطع در فیلترها) [۲].


به طور کلی، تبدیل wavelet رایج‌ترین ابزار برای فشرده‌سازی تصاویر است و از روی ضرایب sparse، بازسازی تصویر انجام می‌شود. گرچه تصویر بازسازی شده با تصویر اصلی تفاوت‌هایی خواهد داشت و اطلاعاتی از دست خواهد رفت. این روش برای تصاویر MRI هم کاربرد دارد، اما در کاربردهای پزشکی حساس به تشخیص، ممکن است قابل قبول نباشد و باید توسط رادیولوژیست‌ها ارزیابی شود [۲].

شکل ۲-۵، نمونه‌ای از یک تصویر MRI مغز را در حوزه‌ی مکان و wavelet نشان می‌دهد. این تصویر در حوزه‌ی مکان غیر sparse است، اما اندازه‌ی ضرایب تبدیل wavelet آن، sparse است. در نتیجه تبدیل wavelet، یک تبدیل sparsify کننده محسوب می‌شود.



شکل ۲-۵- شماتیکی از یک تصویر MRI مغزی در حوزه‌ی مکان و حوزه‌ی تبدیل wavelet


حال می‌توانیم روی ضرایب تبدیل wavelet تصویر شکل ۲-۵ یک آستانه گذاشته و مقدار نویز آن را کاهش دهیم (Denoise کردن). بعد از انجام این آستانه گذاری، مرزهای تصویر در حوزه wavelet مشخص تر خواهند شد. سپس با انجام عکس تبدیل wavelet، می‌توانیم تصویر denoise شده را بازسازی کنیم (شکل ۲-۶).



شکل ۲-۶- ضرایب *denoise* شده‌ی حوزه‌ی *wavelet* به همراه تصویر *MRI* مغز حاصل شده از گرفتن عکس تبدیل

wavelet

لذا تنها با رفتن به یک فضایی که تصویر در آن فضا *sparse* است، به کمک آستانه‌گذاری و برگشتن به فضای مکان، می‌توان به خوبی نویز را از سیگنال جدا کرد (شکل ۲-۷).



شکل ۲-۷- مقایسه‌ی تصویر *MRI* اولیه و تصویر *denoise* شده به کمک تبدیل *wavelet*


نکته‌ای مهم این است که چون ما به تصویر *sparse* شده نیازمندیم، می‌توانیم تنها ضرایب غیر صفر تبدیل *wavelet* را نگه داریم. همچنین می‌توانیم عمل بازسازی را تنها با بخشی از ضرایب انجام دهیم. طبیعتاً هرچه ضرایب بیشتری را در نظر بگیریم، تصویر بازسازی شده به تصویر اصلی شبیه‌تر خواهد بود.

۲-۳- کم‌نمونه برداری (*Undersampling*)

همان‌طور که مشاهده شد، توانستیم بعد از انتقال تصویر به یک فضای *sparse*، آن را *denoise* کرده و بازسازی کنیم. همچنین دیدیم که در *CS*، می‌توان تصویر را به کمک بخشی از فضای *k* بازسازی کرد لذا برای انجام این عمل در واقعیت، نیازمند نمونه‌برداری از فضای *k* هستیم. در ادامه، به بررسی برخی از روش‌های نمونه برداری از فضای *k* یا ماسک نمونه‌برداری پرداخته می‌شود.

۲-۳-۱- نمونه‌برداری با نرخ نایکویست


می‌دانیم که برای جلوگیری از دگرنامی (*aliasing*) باید نرخ نمونه‌برداری با قضیه‌ی نایکویست تعیین شود. شکل ۲-۸ یک نمونه فضای *k*ی تصویر مغز را نشان می‌دهد که با نرخ نایکویست نمونه برداری شده و سپس تصویر آن به کمک عکس تبدیل فوریه بازسازی شده است.



شکل ۲-۸- نمونه برداری از فضای k ی یک تصویر با نرخ نایکویست و بازسازی تصویر با گرفتن عکس تبدیل فوریه

۲-۳-۲- نمونه برداری یکنواخت (کمتر از نرخ نایکویست)


می دانیم که اگر با نرخ کمتر از نرخ نایکویست، نمونه برداری انجام شود، تصویر بازسازی شده دچار aliasing خواهد شد. شکل ۲-۹، ۲ نمونه از این حالت را که با روش نمونه برداری کارترین حاصل شده نشان می دهد. با توجه به این شکل، مشاهده می شود که نمونه برداری منظم، باعث بروز یک اعوجاج منظم در تصویر می شود. همچنین با کاهش نرخ نمونه برداری، این اعوجاج تشدید می شود و اصلاح آن دشوار تر می شود.



شکل ۲-۹- نمونه برداری یکنواخت فضای k با نرخ کوچک تر از نایکویست و نمایش تصویر بازسازی شده


۲-۳-۳- نمونه برداری تصادفی (کمتر از نرخ نایکویست)

شکل ۲-۱۰، نتیجه‌ی نمونه برداری کاملاً تصادفی از فضای k و تصویر بازسازی شده را نشان می‌دهد. مشاهده می‌شود که یک نویز غیر منظم به تصویر اضافه شده است.



شکل ۲-۱۰- نمونه برداری تصادفی از فضای k با نرخ کمتر از نایکویست و نمایش تصویر بازسازی شده


می‌دانیم که اکثر مولفه‌های فرکانسی تصویر، حول فرکانس صفر تجمع یافته‌اند، چه میشد اگر همچنان نمونه برداری تصادفی بوده ولی چگالی نمونه برداری اطراف فرکانس صفر افزایش پیدا می‌کرد؟ شکل ۲-۱۱ نتیجه‌ی بازسازی تصویر با استفاده از نمونه برداری تصادفی با چگالی متغیر را نشان می‌دهد. مشاهده می‌شود که نسبت به شکل ۲-۱۰، آن ابر تار کننده از بین رفته و آرتیفکت ناشی از کم نمونه برداری، خود را صرفاً به شکل نویز نشان داده است.



شکل ۲-۱۱- نمونه برداری تصادفی با چگالی متغیر از فضای k با نرخ کمتر از نایکویست و نمایش تصویر بازسازی شده

۲-۳-۴- نمونه برداری دایروی (کمتر از نرخ نایکویست)

شکل ۲-۱۲، تصویر بازسازی شده به کمک نمونه برداری دایروی از فضای k را نشان می دهد. این نوع نمونه برداری باعث ایجاد یک آرتیفکت خطی در تصویر می شود. طبق مطالعات انجام شده، برای تصاویر sparse، این نوع آرتیفکت بی خطر است و به راحتی می توان آن را حذف نمود و تصویری بهتر از تصویر حالت نمونه برداری تصادفی با چگالی متغیر بازسازی کرد.




شکل ۲-۱۲- نمونه برداری دایروی از فضای k با نرخ کمتر از نایکویست و نمایش تصویر بازسازی شده

۲-۴- روش Compressed Sensing

تا به اینجا متوجه شدیم که اکثر سیگنال‌ها و تصاویر، می‌توانند یک در یک فضای خاص، sparse باشند (مثلا در فضای تبدیل wavelet). همچنین دیدیم که در فضای sparse، denoise کردن بسیار آسان‌تر می‌باشد (تنها به کمک آستانه‌گذاری). در ادامه، دیدیم که وقتی از سیگنال‌ها با نرخ کمتر از نرخ نایکویست، نمونه‌برداری کنیم، alising رخ می‌دهد. همچنین با تغییر روش نمونه برداری (تصادفی با چگالی متغیر یا دایروی)، alising رخ داده بسیار شبیه به نویز به نظر می‌رسد. حال می‌توانیم به کمک ایده‌ی denoise کردن سیگنال sparse، سیگنال کم‌نمونه برداری شده را denoise کرده و بازسازی کنیم. این دقیقا ایده‌ی اصلی روش CS می‌باشد.

۲-۴-۱- مثال بازسازی سیگنال با روش CS


شکل ۲-۱۳، مثالی ساده از بازسازی یک سیگنال به روش CS را نشان می‌دهد. نکته‌ای بسیار مهم این است که طبق شکل، این سیگنال در فضای فرکانسی، sparse است. در این مثال، سیگنال استفاده شده حاصل جمع ۲ سیگنال فرکانس بالا و یک سیگنال با فرکانس کوچک می‌باشد. ابتدا از سیگنال ذکرشده، به صورت تصادفی نمونه‌برداری شده و سپس عکس تبدیل فوریه گرفته می‌شود. مشاهده می‌شود که یک نویز به ظاهر غیر منظم و تصادفی در فضای فرکانسی دیده می‌شود. می‌بینیم که دو مولفه‌ی فرکانس بالا یعنی مولفه‌ی آبی و نارنجی، به راحتی توسط آستانه‌گذاری قابل جداسازی هستند. لذا آستانه‌گذاری کرده و آن دو مولفه را جدا می‌کنیم. چون الگوی نمونه‌برداری را می‌دانیم، می‌توانیم نویز ناشی از آن نمونه‌برداری را به دو مولفه‌ی جداسازی شده اضافه کنیم و از فضای فرکانسی اصلی آن را کم کنیم تا فقط مولفه‌ی فرکانس کوچک باقی بماند. اکنون می‌توانیم این مولفه را نیز به کمک آستانه‌گذاری جدا کرده و پس از جمع کردن با دو مولفه‌ی فرکانس بالا، سیگنال اصلی را بازسازی کنیم. گرچه این روش دقیق نیست و اضافه کردن نویز به سیگنال‌های جداسازی شده، به صورت ایده‌آل انجام نمی‌شود و ممکن است سیگنال فرکانس کوچک به راحتی قابل جداسازی نباشد.



شکل ۲-۱۳- مثالی ساده از روش CS برای یک سیگنال تک بعدی

۲-۴-۲- sparsity در روش CS


همانطور که تا به اینجای این فصل مشاهده شد، سیگنال/تصویر مدنظر می‌تواند sparse نباشد اما باید یک در یک حوزه‌ای مثل حوزه‌ی فرکانس یا wavelet، sparse باشد. همچنین دیدیم که نمونه برداری باید به صورت تصادفی باشد تا alising ایجاد شده شبیه یک نویز نامنظم عمل کند تا بازسازی تصویر مدنظر قابل انجام باشد. شماتیک مربوطه در شکل ۲-۱۴ آورده شده است.



شکل ۲-۱۴ - حیطه‌های سیگنال، *sparse* و نمونه‌برداری در روش CS

۲-۴-۳- مثال بازسازی تصویر با روش CS

در این مثال، داده‌ی اخذ شده در واقع داده‌ی کم‌نمونه‌برداری شده به صورت تصادفی از فضای k می‌باشد. گام اول، بازسازی تصویر به کمک تبدیل فوریه‌ی معکوس می‌باشد. همانطور که مشاهده می‌شود، این تصویر پوشیده شده از نویز نامنظم. سپس از تصویر حاصل شده، تبدیل wavelet می‌گیریم تا به فضای *sparse* منتقل شویم. مشاهده می‌شود که برخی از ضرایب wavelet به صورت کامل در نویز دفن شده و برخی ضرایب دیگر، قابل رویت هستند. در این گام، عملیات *sparse denoising* را انجام می‌دهیم که ساده‌ترین نوع آن، آستانه‌گذاری می‌باشد. سپس عکس تبدیل wavelet گرفته و تصویر *denoise* شده را بازسازی می‌کنیم. این تصویر نسبت به قبل، SNR بیشتری دارد. حال می‌توانیم الگوریتم را همین‌جا به پایان برسانیم، یا برای چندین مرتبه‌ی دیگر ادامه دهیم، یعنی از تصویر بازسازی شده، تبدیل فوریه بگیریم، فضای فرکانسی کم‌نمونه‌برداری شده‌ی اولیه را به‌روزرسانی کرده و الگوریتم را تکرار کنیم تا به سطح مورد نظر از SNR برسیم.




شکل ۲-۱۳- مثالی از روش CS برای یک تصویر MRI مغز

۲-۴-۴- CS، مسئله‌ی بهینه‌سازی؟

با توجه به شکل ۲-۲ دیدیم که می‌توان از روی تعداد دادگان اندک از فضای k ، تصویری شبیه به تصویر اصلی بازسازی نمود. اما دقیقاً با انتخاب چند درصد از فضای k ، تصویری با SNR مد نظر حاصل می‌شود؟ می‌توانیم به این مسئله به دید یک مسئله‌ی بهینه‌سازی نگاه کنیم. درواقع باید کمترین تعداد المان‌های فضای sparse را منجر به بازسازی ایده‌آل می‌شود، محاسبه کنیم. این فرایند به کمک نرم‌های مختلف صورت می‌گیرد که در این گزارش، از نرم صفر استفاده شده است (رابطه‌ی (۱) [۲]).

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}, \text{ where } (p=0) = \|x\|_0 = \sum_{i=1}^n 1(x_i \neq 0) \quad (1)$$

در واقع نرم صفر، صرفاً تعداد المان‌های غیر صفر یک بردار را می‌شمارد. از آنجایی که این تابع محدب (convex) نیست (شکل ۲-۱۴)، بهینه‌سازی آن کار دشواری است و احتمال گیر افتادن در اکسترموم‌های محلی بالا می‌باشد [۲]. مقاله‌ای که در این پروژه بررسی شده است، تا حد امکان این مشکل را با ارائه‌ی روشی نوین برطرف نموده است.



شکل ۲-۱۴- نمونه‌ای از سیگنال محدب و غیر محدب [۹]

۲-۴-۵- الزامات دنیای واقعی روش CS

- برخی تصاویر پزشکی sparsity قوی ندارند.
- نویز در حوزه‌ی sparse (wavelet)
 - نمونه برداری، باعث کاهش SNR می‌شود
 - نویز موجود سفید یا گوسین نیست.
- نمونه برداری کاملاً تصادفی و بدست آوردن نویز کاملاً نامنظم، ممکن نیست
- نمونه برداری تصادفی فضای k ، نیازمند سوییج کردن‌های پی در پی کویل‌های گرادیان است و این قضیه در عمل دشوار است بخاطر جریان‌های ادی (Eddy currents) و آرتیفک‌های مربوطه. پس علاوه بر مشکلات نرم‌افزاری، یک مشکل سخت‌افزاری هم داریم.
- ما فقط اندازه‌ی ضرایب تبدیل wavelet را در نظر گرفتیم اما در واقعیت، ضرایب wavelet، اعدادی مختلط هستند و علاوه بر اندازه، فاز هم دارند.

۲-۵- جمع‌بندی

در این فصل به معرفی روش CS و اجزای مختلف آن پرداخته شد. در فصل بعد وارد توضیح و پیاده‌سازی مقاله می‌شویم.

فصل سوم

توضیح و پیاده‌سازی مقاله

در این فصل به توضیح کامل بخش‌های مختلف مقاله پرداخته می‌شود. هر بخشی که در فصل‌های پیشین به آن اشاره نشده باشد، بیشتر توضیح داده می‌شود، یعنی توضیحاتی مضاف بر مقاله گفته می‌شود. همچنین در بخش روش انجام پژوهش، هر رابطه که توضیح داده می‌شود، بعد از آن کد مربوطه در پایتون نیز آورده شده است. در مواقعی نیز کدها به عنوان نمونه اجرا شده‌اند تا عملکرد هر تکه از الگوریتم تست و نشان داده شود. همچنین هر نموداری که در مقاله وجود داشته است، کد مربوط به آن نوشته شده، پیاده‌سازی شده و خروجی‌اش نشان داده شده است. در بخش نتایج هم علاوه بر نتایج مشابه با مقاله، نتایجی جزئی تر آورده شده و مقایسه‌های دقیق‌تری انجام شده. در نهایت، دلایل احتمالی اختلاف نتایج بنده با نتایج مقاله آورده شده است.

در فصل بعد نتیجه‌گیری انجام شده و انتقاداتی به مقاله و همچنین به پیاده‌سازی خویش وارد می‌کنم.

۳-۱- معرفی مقاله

لینک دسترسی به مقاله:

[ISRSLO: compressed sensing MRI with image smoothness regularized-smoothed \$l_0\$ norm](#)

تصویر صفحه‌ی اول مقاله:

scientific reports

[Explore content](#) ▾ [About the journal](#) ▾ [Publish with us](#) ▾

[nature](#) > [scientific reports](#) > [articles](#) > article

Article | [Open access](#) | Published: 16 October 2024

ISRSLO: compressed sensing MRI with image smoothness regularized-smoothed ℓ_0 norm

[Elaheh Hassan](#) & [Aboozar Ghaffari](#) 

[Scientific Reports](#) **14**, Article number: 24305 (2024) | [Cite this article](#)

شکل ۴-۱- تصویر صفحه‌ی اول مقاله‌ی انتخاب شده

۳-۲- چکیده

بازسازی تصاویر MRI همواره یک مسئله معکوس چالش‌برانگیز در تصویربرداری پزشکی بوده است. شتاب‌دادن به فرایند اسکن MRI برای پژوهش‌های بالینی و کاربردهای پیشرفته از اهمیت زیادی برخوردار است. یکی از تلاش‌های اصلی برای دستیابی به این هدف، استفاده از روش CS است. هدف CS بازسازی تصاویر MRI با استفاده از تعداد کمی داده‌ی نمونه‌برداری‌شده در فضای k است. با این حال، این روش‌ها با چالش‌هایی مانند احتمال از دست رفتن ساختارهای ریز تصویر و افزایش پیچیدگی محاسباتی روبه‌رو هستند. در این پژوهش، یک چارچوب جدید بر پایه یک مسئله بازیابی sparse منظم‌سازی‌شده^۱ و یک مرحله‌ی تیزسازی^۲ معرفی شده تا روش‌های CS-MRI را از نظر حفظ ساختارهای ریز در ضرایب شتاب بالا بهبود

¹ regularized sparse recovery

² sharpening

دهد. این مسئله با استفاده از روش ^2HQS حل می‌شود. مسئله‌ی معکوس بازسازی تصویر MRI به دو زیرمسئله‌ی مجزا تبدیل می‌شود که هر یک را می‌توان به‌طور جداگانه حل کرد. یکی از ویژگی‌های کلیدی رویکرد پیشنهادی این است که یکی از زیرمسئله‌ها با یک denoiser جایگزین می‌شود. این منظم‌سازی به بهینه‌سازی هموارشده l_0 (SL₀) کمک می‌کند تا از مینیوم‌های محلی اجتناب کرده و دقت آن را افزایش دهد. روش پیشنهادی شامل سه گام است: هموارسازی^۵، اصلاح ویژگی‌ها و بهینه‌سازی تابع هزینه‌ی SL₀. این رویکرد الگوریتم SL₀ را برای بازسازی تصاویر MRI بهبود می‌دهد بدون آن‌که آن را پیچیده‌تر کند. همگرایی روش پیشنهادی نیز به‌صورت تحلیلی نشان داده شده است و نتایج تجربی عملکرد قابل قبول آن را در مقایسه با روش‌های مبتنی بر شبکه‌های عمیق نشان می‌دهند.

۳-۳-۲- مقدمه

در دهه‌های اخیر، MRI به روشی پیشرو برای تشخیص بیماری‌ها تبدیل شده و روش CS به‌عنوان استراتژی موفق برای بازسازی تصاویر با نرخ نمونه‌برداری پایین‌تر از نایکوئیست بدون افت بالای کیفیت مطرح است.

۳-۳-۱- معرفی روش CS

CS از این واقعیت بهره می‌گیرد که تصویر معمولاً در برخی دامنه‌های تبدیل مناسب، sparse است؛ مانند دامنه‌های wavelet یا المان محدود، به‌شرط آن‌که فرایند اخذ داده از اصول ناهم‌ربطی^۶ پیروی کند. در این زمینه، ناهم‌ربطی برای برهم‌زدن نظم متعارف در الگوهای نمونه‌برداری حیاتی است و امکان استفاده از روش‌های بازسازی مبتنی بر sparsity را فراهم می‌کند. هدف، دور شدن از الگوهای نمونه‌برداری سیستماتیک و پیش‌بینی‌پذیر است، تا بتوان تصاویر باکیفیت را از مجموعه‌ای کاهش‌یافته از نمونه‌های غیرتکراری بازسازی کرد. در اغلب روش‌های اولیه‌ی CS-MRI، مدل شامل دو جزء اصلی است: یک جزء

³ Half Quadratic Splitting

⁴ smoothed l_0 norm

⁵ smoothing

⁶ incoherence

وفاداری به داده^۷ در فضای k و یک جزء منظم‌سازِ نمایش sparse در دامنه‌های مختلف مانند المان محدود و wavelet. با این حال، یک ضعف مهم این روش‌های کلاسیک، از دست رفتن قابل توجه ساختارها و جزئیات در تصاویر بازسازی‌شده، به‌ویژه در نرخ‌های کم‌نمونه‌برداری بالا است.

۳-۳-۲- معرفی برخی روش‌های دیگر بازسازی تصاویر MRI

بعد از فراگیر شدن مفهوم sparsity و تبدیل‌هایی که این ویژگی را برآورده می‌کنند، رویکردهای متعددی مانند یادگیری دیکشنری چندکلاسه^۸ (FDLCP) و تکنیک‌های، آستانه‌گذاری پی در پی مثل SFISTA^۹ و PFISTA^{۱۰} برای حل مسئله معکوس CS-MRI توسعه یافته‌اند، هرچند با چالش‌هایی مانند پیچیدگی محاسباتی روبه‌رو هستند.

علاوه بر روش‌های کلاسیک، رویکردهای مبتنی بر یادگیری عمیق نیز توانسته‌اند در حوزه‌های مختلف مثل بازسازی، کاهش نویز و طبقه‌بندی تصاویر MRI، موفق باشند. مزیت اصلی این روش‌ها توانایی آن‌ها در یادگیری ویژگی‌ها و الگوهای پنهان و پیچیده‌ی تصاویر است. مدل‌های یادگیری عمیق مانند IFR-CS^{۱۱} و KTMR^{۱۲} در بازسازی MRI موفقیت‌آمیز بوده‌اند، اما نیاز به داده‌های آموزشی زیاد و هزینه محاسباتی بالا دارند.

۳-۳-۳- الگوریتم SL0

برای دستیابی به sparse‌ترین نمایش ممکن از تصاویر MRI، از نُرم ℓ_0 نرم شده (SL0) استفاده شده است. این نرم تعداد مؤلفه‌های غیرصفر در تصویر را کمی‌سازی می‌کند. مزیت اصلی SL0 کارایی محاسباتی

⁷ data fidelity

⁸ Fast Multiclass Dictionary Learning

⁹ Smoothing Fast Iterative Shrinkage-Thresholding Algorithm

¹⁰ Projected Fast ISTA

¹¹ Iterative Feature Refinement Compressed Sensing

¹² K-space Transformer MRI Reconstruction Model

آن است. این روش ۲ تا ۳ برابر سریع‌تر از روش‌های کلاسیک CS مثل ^{13}BP (مبتنی بر نرم ℓ_1) عمل می‌کند در حالی که دقت مشابه یا بهتر دارد. با وجود این، SL0 با مشکل مینیوموم‌های محلی^{۱۴}، به‌ویژه هنگام بالا بودن سطح sparsity، و همچنین حساسیت به نویز روبه‌رو است.

۳-۳-۴- نوآوری مقاله

- در این مقاله، یک جمله‌ی منظم‌ساز مبتنی بر هموارسازی تصویر به الگوریتم SL0 افزوده می‌شود. این منظم‌سازی برای جلوگیری از گیر افتادن در مینیوموم‌های محلی در فرایند بهینه‌سازی به کار می‌رود.
- الگوریتم پیشنهادی در طیف گسترده‌ای از ماسک‌های نمونه‌برداری و نرخ‌های نمونه‌برداری مختلف عملکرد قدرتمندی نشان می‌دهد که نشان‌دهنده‌ی تطبیق‌پذیری و پایداری آن در سناریوهای متنوع اخذ MRI است.
- مسئله‌ی بهینه‌سازی پیشنهادی به‌طور مؤثر با استفاده از روش HQS حل می‌شود که مسئله را به دو زیرمسئله‌ی جداگانه (denoising و بازیابی sparse) تجزیه می‌کند و همگرایی کارا و پایدار را تضمین می‌نماید.
- عملکرد الگوریتم پیشنهادی در مقایسه با روش‌های پیشرفته مبتنی بر یادگیری عمیق رقابت دارد، در حالی که از مزایای سادگی و پیچیدگی محاسباتی کم نیز برخوردار است.

¹³ Basic Pursuit

¹⁴ Local Minimum

۳-۴- روش انجام پژوهش

هدف این مطالعه بهبود الگوریتم SL0 است با افزودن یک شرط هموارسازی است تا هم خط همگرایی به مینیموم‌های محلی کاهش یابد و هم دقت روش افزایش یابد. در عین حال پیچیدگی محاسباتی‌اش افزایش پیدا نکند. با این حال، این هموارسازی ممکن است به‌طور ناخواسته بعضی از جزئیات تصویر را حذف کند. اثر جانبی این مشکل با دو تکنیک کنترل می‌شود:

۱. **ضریب کاهشی** که سطح هموارسازی را در هر تکرار^{۱۵} کاهش می‌دهد

۲. **عملگر تیزسازی** برای جبران‌سازی جزئیات حذف‌شده

۳-۴-۱- الگوریتم SL0

تکنیک بهینه‌سازی نرم ℓ_0 رویکردی محبوب در بازیابی سیگنال/تصویر sparse است، جایی که هدف تقریب نرم ℓ_0 با یک تابع نرم و پیوسته است که بهینه‌سازی آن آسان‌تر باشد. روش SL0 به‌عنوان جایگزینی برای تکنیک‌های مینیمم‌سازی سنتی ℓ_1 که به‌طور گسترده در CS استفاده می‌شوند، به‌کار گرفته شده است. در بهینه‌سازی SL0، نرم ℓ_0 با خانواده‌ای از توابع هموار تقریب زده می‌شود که با میل کردن پارامتر هموارسازی به صفر، به ℓ_0 همگرا می‌شوند. این رویکرد بهینه‌سازی کارا را ممکن می‌سازد، زیرا مسئله‌ی بهینه‌سازی نرم ℓ_0 را که غیرمحدب بود (شکل ۲-۱۴)، به چند مسئله‌ی هموار می‌شکند که با تکنیک‌های رایج بهینه‌سازی مثل گرادیان کاهش، قابل حل است.

$$\|s\|_{0,\sigma} = m - F_\sigma(s) = m - \sum_{i=1}^m \exp\left(-\frac{s_i^2}{2\sigma^2}\right) \approx \|s\|_0 \quad (2)$$


هدف، کمینه کردن $\|s\|_{0,\sigma}$ است زیرا نرم ℓ_0 ، تعداد المان‌های غیر صفر یک بردار را می‌شمارد و این تعداد هرچه کمتر باشد، آن بردار sparse تر است و این دقیقاً در راستای هدف روش CS می‌باشد. در رابطه‌ی (۲)، m ابعاد ورودی s را نشان می‌دهد. همچنین σ ، پارامتر هموارسازی است. هرچه بزرگ‌تر باشد، نرم

¹⁵ Iteration

نمایی تابع F دیرتر افت می‌کند، شکل تابع هموارتر شده، بهینه‌سازی آسان‌تر، تقریب نرم ℓ_0 ضعیف‌تر شده و sparsity را کمتر می‌تواند مدل کند. برای $\sigma = 0$ ، این تابع دقیقاً نرم ℓ_0 را نشان می‌دهد.

در الگوریتم استفاده شده، از یک توالی نزولی σ و تکنیک گرادیان کاهشی استفاده می‌شود. به این ترتیب در ابتدا که σ بزرگ است، تابع شکل بسیار همواری دارد و به راحتی می‌تواند به یک ناحیه‌ی خوب حرکت کند. با کاهش σ ، میزان همواری تابع کمتر شده، sparsity بیشتر و تقریب تیزتر می‌شود، اما همچنان مینیموم پیدا شده، نزدیک به ناحیه‌ی قبلی است و به این ترتیب رسیک گیر افتادن در مینیموم‌های محلی کاهش پیدا می‌کند و لی همچنان این خطر وجود دارد.

شکل ۴-۲، نمودار کشیده شده از رابطه‌ی (۱) را برای نشان می‌دهد که کد آن در پایتون نوشته شده و تابع پایتون آن در ادامه آورده شده است.



شکل ۴-۲- تابع $SL0$ برای مقادیر مختلف σ

❖ کد مربوط به شکل ۴-۲ (کد مربوط به رسم شکل آورده نشده است تا گزارش، شلوغ نشود. در فایل ipynb، کد های کدها و نتایج موجود می‌باشند):

```
def smooth_l0_norm(x, sigma):
    return 1.0 - np.exp(-x**2 / (2.0 * sigma**2))
```

طبق شکل ۴-۲ مشاهده می‌شود که با افزایش σ ، شکل تابع، هموار تر می‌شود و آهسته‌تر افت می‌کند. همچنین با کاهش σ ، شکل تابع تیز تر می‌شود و به نرم ℓ_0 نزدیک‌تر می‌شود.

۳-۴-۲- ایده‌ی اصلی

در این بخش برای بهبود عملکرد تابع SL0، یک المان تنظیم کننده به آن اضافه می‌شود. فرض کنید که تصویر s ، تحت تبدیل wavelet (Ψ عکس تبدیل wavelet است)، به یک فضایی می‌رود که sparse است (α ضرایب تبدیل wavelet است). همچنین چیزی که ما اندازه می‌گیریم (فضای k در MRI) y نام داشته باشد و ماتریس A ، شبیه تبدیل فوریه عمل کند و تصویر s را به y تبدیل کند. آنگاه رابطه‌ی (۳) به این ترتیب تعریف می‌شود.

$$y = A.s = A\Psi\alpha, \quad \alpha = \Psi^{-1}s \quad (3)$$

در حوزه‌ی بازسازی تصویر، درواقع ما از روش SL0 که معرفی کردیم استفاده می‌کنیم تا sparse ترین نمایان‌گر تصویر (α) را پیدا می‌کنیم. در این‌جا، کمینه‌کردن نرم SL0، به عنوان یک معیار sparsity عمل می‌کند. درواقع هدف کمینه کردن تعداد ضرایب غیر صفر در α می‌باشد. پس مسئله‌ی بهینه‌سازی، مطابق رابطه‌ی (۴) بدست می‌آید.

$$\hat{\alpha} = \min ||\alpha||_{0,\sigma}, \quad y = A\Psi\alpha \quad (4)$$

همانطور که گفته شد، رفتن از نرم ℓ_0 به نرم SL0، ریسک گیر افتادن در مینیموم محلی را کاهش می‌داد اما همچنان این خطر وجود دارد، مخصوصاً زمانی که نرخ نمونه‌برداری خیلی پایین باشد یا نویز بالا باشد. در حال حاضر، الگوریتم فقط sparsity را کمینه می‌کند (رابطه‌ی ۴). اگر به این الگوریتم یک ترم smoothing اضافه کنیم، احتمال همگاری بیشتر و تصویر بازسازی شده، کیفیت بیشتری خواهد داشت. دلیل دیگری که این کار کمک کننده است این است که تصاویر MRI، به صورت طبیعی smooth هستند و مدل بازسازی

ما باید حد امکان تصاویر شبیه تصاویر واقعی درست کند، نه تصاویری صرفاً با مرزهای تیز و مشخص (sparse). لذا، الگوریتم اصلی این مقاله یعنی **ISRSLO**^{۱۶} به این ترتیب نوشته می‌شود:

$$\hat{s} = \underset{s}{\operatorname{argmin}} ||\Psi^{-1}s||_{0,\sigma} + \lambda_s \cdot \text{smoothness}(s) \quad , \quad y = As = A\Psi\alpha \quad (5)$$

رابطه‌ی ۵ از آن‌جا نشأت می‌گیرد که بعد از بهینه کردن ضرایب α ، تصویر جدید $\hat{s}$ ساخته می‌شود. همچنین، λ_s میزان هموارسازی را تنظیم می‌کند. هرچه این پارامتر بزرگ‌تر باشد، تصویر بازسازی شده، هموارتر و هرچه این ضریب کوچک‌تر باشد، تصویر بازسازی شده، sparse تر خواهد بود. همچنین تابع $\text{smoothness}(s)$ در ادامه در غالب یک denoiser تعریف خواهد شد.

برای خلاص شدن از ترم $y = A\Psi\alpha$ ، رابطه‌ی ۵ را به صورت زیر بازنویسی می‌کنیم:

$$\hat{s} = \underset{s}{\operatorname{argmin}} J(s) \quad , \quad J(s) = ||\Psi^{-1}s||_{0,\sigma} + \lambda_s \cdot \text{smoothness}(s) + \delta_c(s) \quad (6)$$

$\delta_c(s)$ برای s هایی در رابطه‌ی $y=As$ صدق نمی‌کنند، بی‌نهایت بوده یعنی بهینه‌سازی را غیر ممکن می‌سازد. در غیر این صورت، $\delta_c(s)$ صفر خواهد بود و اثری روی بهینه‌سازی ندارد. به عبارتی، $\delta_c(s)$ نشان دهنده‌ی مقیاس فضای اندازه‌گیری k -space ماست.

۳-۴-۱- شکستن الگوریتم ISRSLO به دو مسئله‌ی مجزا

تا به اینجا دیدیم که روش ISRSLO به ۲ مسئله‌ی sparsity و smoothness تقسیم شد. اما در رابطه‌ی ۶، این ۲ مسئله در دل هم دیگر هستند و حل آن دشوار است. لذا به کمک یک روش ریاضی به نام Half Quadratic Splitting (HQS)، یک متغیر فرضی به مسئله اضافه کرده و این رابطه را به ۲ مسئله‌ی کوچک‌تر شکسته و هر مسئله را جداگانه حل می‌کنیم. به این ترتیب می‌توان مسائل sparsity و smoothness را به صورت جداگانه بهینه کرد. روش HQS تکنیکی قدرتمند و معروف برای حل مسائل معکوس مانند بازسازی CS-MRI است.

¹⁶Image Smoothness-regularized SLO

$$J_{HQS}^p(s, z) = ||\Psi^{-1}s||_{0,\sigma} + \lambda_s \cdot smoothness(z) + \delta_c(s) + \frac{1}{2\lambda_p} |s - z|_2^2 \quad (7)$$

به طوری که $|s - z|_2^2$ ، نرم اغلیدوئی (l2) بین s و z می‌باشد. اکنون مشاهده می‌شود که ترم $smoothness$ دیگر روی z اعمال شده و ترم $sparsity$ روی s . همچنین λ_p ، برای اختلاف بین s و z پناستی تعیین می‌کند. هرچه این پارامتر کوچک‌تر ، پناستی بزرگ‌تر می‌شود. حال رابطه‌ی ۷ را به ۲ مسئله‌ای که گفتیم می‌شکنیم و s و z را جداگانه بدست می‌آوریم:

$$z_{k+1} = \underset{z}{\operatorname{argmin}} J_{HQS}^p(s_k, z) = \underset{z}{\operatorname{argmin}} (\lambda_s \cdot smoothness(z) + \frac{1}{2\lambda_p} |s_k - z|_2^2) \quad (8)$$

$$s_{k+1} = \underset{s}{\operatorname{argmin}} J_{HQS}^p(s, z_{k+1}) = \underset{s}{\operatorname{argmin}} (||\Psi^{-1}s||_{0,\sigma} + \delta_c(s) + \frac{1}{2\lambda_p} |s - z_{k+1}|_2^2) \quad (9)$$

۳-۴-۳ denoise کردن

می‌توان به رابطه‌ی (۸) به عنوان denoise کردن s_k و بدست آوردن z_{k+1} نگاه کرد که $\frac{1}{2\lambda_p} |s_k - z|_2^2$ به ما می‌گوید که چقدر نسخه‌ی denoise شده‌ی s_k به نسخه‌ی اولیه‌ی خودش تفاوت دارد. در مقاله به آن تحت عنوان fidelity term ذکر شده. لذا رابطه‌ی (۸) را به این صورت بازنویسی می‌کنیم:

$$z_{k+1} = D(s_k, g(k)) \quad , \quad \mathbf{D}: \text{denoiser: BM3D or WIENER}, \mathbf{g}(\mathbf{k}): \text{noise level} \quad (10)$$

در این رابطه، D می‌تواند هر denoiser باشد اما در مقاله از BM3D و WIENER استفاده شده است. در فصل قبل دیدیم که ساده‌ترین denoiser در فضای sparse، یک آستانه‌گذاری ساده است (شکل ۲-۱۴ و ۲-۱۵). پارامتر $g(k)$ نیز میزان smoothness را تنظیم می‌کند و رابطه‌اش مطابق زیر است:

$$g(k) = \frac{0.08}{\text{Sampling rate \%}} \times \sigma_k \quad (11)$$

طبق رابطه‌ی ۱۱، تابع $g(k)$ به دنباله‌ی نزولی σ_k وابسته است و با هر iteration، کاهش پیدا می‌کند. پس در نتیجه اگر دوباره به رابطه‌ی ۷ دقت کنیم، می‌بینیم که با گذشت iterationها، $g(k)$ که پارامتر کنترل کننده‌ی smoothness بود کاهش می‌یابد و تنها ترم sparsity یعنی نرم SL0 یا $\|\Psi^{-1}s\|_{0,\sigma}$ باقی می‌ماند. همچنین پارامتر $\text{Sampling rate \%}$ نشان می‌دهد که چند درصد از فضای k نگه‌داشته شده است. منطقی است که هرچه این پارامتر بزرگ‌تر باشد، $g(k)$ باید کوچک‌تر شود، برای همین با آن نسبت عکس دارد. همچنین ضریب 0.08 به صورت تجربی بدست آمده است و این مقدار بالانس مناسبی بین میزان smoothness و حفظ جزئیات تصویر است.

در ادامه‌ی این بخش، درباره‌ی دو denoiser اشاره شده یعنی BM3D و WIENER صحبت می‌شود و کد پیاده‌سازی آن‌ها نیز نشان داده می‌شود.

*** در مقاله هیچ توضیحی درباره‌ی این denoiser ها آورده نشده بود! ***


۳-۴-۱- BM3D denoiser [۱۰]

BM3D یکی از بهترین الگوریتم‌های denoising است که بر این پایه کار می‌کند که تصویر در دامنه تبدیل (برای مثال wavelet)، نمایش محلی sparse دارد. این sparsity با گروه‌بندی تکه‌های دوبعدی مشابه به گروه‌های سه‌بعدی تقویت می‌شود. این روش، دو مرحله دارد:

۱. آستانه‌گذاری سخت و تخمین اولیه تصویر denoise شده

۲. اعمال فیلتر WIENER تطبیقی با تخمین فاز و بدست آوردن تصویر نهایی

شکل ۳-۴ بلوک دیاگرام نحوه‌ی عمل کرد روش BM3D را نشان می‌دهد.



شکل ۳-۴- بلوک دیاگرام نحوه‌ی عملکرد *BM3D denoiser* [۱۰]

برای پیاده‌سازی آن در پایتون، از کتابخانه‌ی *scipy* استفاده کردم که دستور مربوط به این denoiser را در خود داشت. ورودی تابعی که نوشتم، تصویر *s* (عکس تبدیل فوریه‌ی فضای *k*یی که نمونه‌برداری شده است) و σ می‌باشد. خروجی هم تصویر *denoise* شده است.

❖ کد مربوط به *BM3D denoiser* :

```
def denoise_bm3d_complex(s, sigma):
    # Separate mag and phase
    mag = np.abs(s)
    phase = np.exp(1j * np.angle(s))

    # Normalize
    m_min, m_max = mag.min(), mag.max()
    mag_norm = (mag - m_min) / (m_max - m_min)

    # Denoise the mag
    den = bm3d(mag_norm, sigma_psd=sigma)

    # convert denoised mag to the initial scale
    den = den * (m_max - m_min) + m_min
    return den * phase
```

[۱۱] WIENER denoiser – ۲-۳-۴-۳

فیلتر وینر یک فیلتر بهینه خطی برای کاهش نویز افزوده در تصویر است که سعی می‌کند میانگین مربعات خطا بین تصویر اصلی و تصویر نویزگیری‌شده را کمینه کند. ایده‌اش این است که بر اساس آمار محلی (میانگین و واریانس در یک همسایگی قابل تنظیم با ساینز کرنل) تشخیص دهد کجا تصویر واقعی است و کجا بیشتر نویز است. در نواحی صاف، خروجی را بیشتر هموار می‌کند و در نواحی دارای لبه و جزئیات، هموارسازی را کمتر می‌کند تا لبه‌ها کمتر تخریب شوند. برای مثال در [دستور wiener2 در متلب](#) ابتدا تصویر نرمال می‌شود، سپس روی هر پیچ کوچک، توان نویز و واریانس محلی برآورد می‌شود و بر اساس آن یک فیلتر کم‌گذر تطبیقی اعمال می‌شود. این فیلتر برای نویز گاوسی افزوده کارایی خوبی دارد، اما به‌طور ذاتی نمی‌تواند اجزای فرکانس بالایی را که به‌طور جدی توسط نویز خراب شده‌اند بازسازی کند، بنابراین ممکن است کمی تاری در تصویر باقی بگذارد.

❖ کد مربوط به *WIENER denoiser* :

```
def denoise_wiener_complex_scipy(s, sigma, kernel_size=3):
    from scipy.signal import wiener

    mag = np.abs(s)
    phase = np.exp(1j * np.angle(s))

    # Normalize
    m_min, m_max = mag.min(), mag.max()
    mag_norm = (mag - m_min) / (m_max - m_min)

    # Apply Wiener filter
    den = wiener(mag_norm, mysize=kernel_size, noise=sigma**2)

    # Denormalize
    den = den * (m_max - m_min) + m_min

    return den * phase
```

۳-۴-۴- تیزسازی

نکته‌ای مهم این است که denoise کردن تصویر، بخاطر فرایند smoothing، باعث از دست رفتن برخی جزئیات تصویر مثل لبه‌ها می‌شود. برای جبران این مسئله، عملگر تیزسازی^{۱۷} (SR) انجام می‌شود و برخی از جزئیات از دست رفته را به تصویر denoise شده باز می‌گرداند. در الگوریتم، وزن SR با گذشت iteration، کاهش پیدا می‌کند. رابطه‌ی عملگر SR به این ترتیب است:

$$SR = 1 - \left| \frac{3\sigma_{pq} + v}{2\sigma_p^2 + 2\sigma_q^2 + v} \right| \quad (12)$$

در رابطه‌ی ۱۲، σ_p^2 واریانس محلی یک قطعه از تصویر قبل از denoise کردن، σ_q^2 واریانس محلی یک قطعه از تصویر بعد از denoise کردن و σ_{pq} کواریانس محلی یک قطعه بین تصویر قبل و بعد از denoise سازی می‌باشد. همچنین پارامتر v صرفاً یک عدد ثابت است و برای پایداری رابطه استفاده می‌شود. این رابطه به این ترتیب کار می‌کند که اگر کوواریانس زیاد باشد، یعنی تصویر قبل و بعد از denoise کردن، اختلاف اندکی دارند، در نتیجه SR حدوداً صفر می‌شود یعنی جزئیات زیادی از تصویر کم نشده و نیازی به تیزسازی نیست.

❖ کد مربوط به *Sharpening Operator*:

```
# ----- Sharpening -----
def compute_SR(z, s_prev, v=1e-6):
    z_mag = np.abs(z)
    s_mag = np.abs(s_prev)
    mu_p = gaussian_filter(z_mag, sigma=1)
    mu_q = gaussian_filter(s_mag, sigma=1)
    mu_p2 = gaussian_filter(z_mag**2, sigma=1)
    mu_q2 = gaussian_filter(s_mag**2, sigma=1)
    mu_pq = gaussian_filter(z_mag * s_mag, sigma=1)

    sigma_p2 = np.clip(mu_p2 - mu_p**2, 0, None)
    sigma_q2 = np.clip(mu_q2 - mu_q**2, 0, None)
    sigma_pq = mu_pq - mu_p * mu_q
```

¹⁷ Sharpening Operator

```
num = 3 * sigma_pq + v
den = 2 * sigma_p2 + 2 * sigma_q2 + v
SR = 1.0 - np.abs(num / den)
return SR
```

۳-۴-۵- ویژگی‌های یک تبدیل unitary [۱۲, ۱۳]

تبدیل U unitary است، اگر در رابطه‌ی زیر صدق کند.

$$\|Ux\| = \|x\|, U \times U^T = U^T \times U = I \rightarrow U^T = U^{-1} \quad (۱۳)$$

پس هم وارون آن با ترانپوز آن برابر است، و هم این‌که مقدار نرم یک بردار یا تصویر مثل x را تغییر نمی‌دهند. برای Unitary کردن تبدیل فوریه و wavelet، کفایت آن‌ها را به ضرب ابعاد x تقسیم کنیم. همچنین برای عکس این تبدیل‌ها، این ضرب در آن‌ها باید ضرب شود. از خواص ذکر شده در رابطه‌ی ۱۳ در ادامه‌ی مقاله استفاده خواهد شد.

❖ کد زیر، تابع تبدیل فوریه دوبعدی unitary و عکس آن را دربر دارد.

```
def fft2c(img):
    return np.fft.fftshift(np.fft.fft2(np.fft.ifftshift(img))) /
    np.sqrt(np.prod(img.shape))

def ifft2c(kspace):
    return np.fft.fftshift(np.fft.ifft2(np.fft.ifftshift(kspace))) *
    np.sqrt(np.prod(kspace.shape))
```

❖ کد زیر، تابع تبدیل wavelet دوبعدی unitary و عکس آن را دربر دارد.

```
def wavelet_forward(img, wavelet='haar', level=4):
    # PyWavelets dwt2 is ALREADY unitary/orthonormal
    coeffs2 = pywt.wavedec2(img, wavelet=wavelet, level=level,
    mode='periodization')
    arr, slices = pywt.coeffs_to_array(coeffs2)
    return arr, slices


def wavelet_inverse(arr, slices, wavelet='haar'):
    coeffs2 = pywt.array_to_coeffs(arr, slices, output_format='wavedec2')
    img = pywt.waverec2(coeffs2, wavelet=wavelet, mode='periodization')
    return img
```

❖ تست Unitary بودن توابع فوریه و wavelet در پایتون:

در فایل ipynb، در بخش proof of unitary fft و proof of unitary wavelet، یک نمونه دیتای زانو لود شده، تبدیل‌های ذکر شده روی آن‌ها گرفته شده و سپس تمامی خواص یک تبدیل unitary تست و ارزیابی شده‌اند. به دلیل طولانی بودن کد (پراز دستورات print و تکراری) در گزارش نیاوردیمش.

۳-۴-۶- اعمال کردن تیزسازی و denoising

حال که روابط مربوط به denoise کردن تصویر و تیزسازی را بدست آوردیم، موقع اعمال آن در الگوریتم است. شکل ۴-۴، بلوک‌دیگرام شماتیک روش ISRSL0 را نشان می‌دهد، تا به اکنون، تا سر مرحله‌ی نگاشت گرادیان، تمام روابط را بررسی کردیم.



شکل ۴-۴- بلوک‌دیگرام شماتیک روش ISRSL0

مطابق شکل ۴-۴، می‌توانیم تابع مربوط به اجرای الگوریتم تا سر مرحله‌ی نگاشت گرادیان را در پایتون بنویسیم:

❖ کد زیر، تابع مربوط به انجام عملیات denoising و تیزسازی است. همچنین تابع‌های denoiser BM3D، denoiser wiener و compute SR را در بخش‌های قبل آورده بودیم.

```
def denoise_and_sharpen(s_prev, sigma_k, sampling_rate, k_outer, denoiser):
    # g(k) from eq. (12)
    gk = 0.08 / (sampling_rate * 100.0) * sigma_k

    # Step 1: Denoise
    if denoiser == 'BM3D':
        z = denoise_bm3d_complex(s_prev, sigma=gk)

    elif denoiser == 'wiener':
        z = denoise_wiener_complex_scipy(s_prev, sigma=gk)

    # # Step 2: sharpening
    SR = compute_SR(z, s_prev)

    z = z + SR * (0.8 ** k_outer) * (s_prev - z) # Sharpen denoised z

    return z
```

۳-۴-۷- کاهش و نگاشت گرادیان

تا به اینجا، رابطه‌ی (۸) را که مربوط به ترم smoothnes از الگوریتم ISRSL0 بود، کامل شرح داده و بررسی کردیم. حال به سراغ رابطه‌ی (۹) می‌رویم که مربوط به ترم sparsity است. این رابطه یک رابطه‌ی بهینه‌سازی است که به کمک روابط گرادیان حل می‌شود و به دو مرحله‌ی کاهش گرادیان و نگاشت گرادیان تقسیم می‌شود (برای درک بهتر رابطه‌ی ۱۴، رابطه‌ی ۹ را هم دوباره آوردم):

$$s_{k+1} = \underset{s}{\operatorname{argmin}} J_{HQS}^p(s, z_{k+1}) = \underset{s}{\operatorname{argmin}} \left(\|\Psi^{-1}s\|_{0,\sigma} + \delta_c(s) + \frac{1}{2\lambda_p} \|s - z_{k+1}\|_2^2 \right) \quad (۹)$$

$$\begin{cases} s = \underset{s}{\operatorname{argmin}} \left(\|\Psi^{-1}s\|_{0,\sigma} + \frac{1}{2\lambda_p} \|s - z_{k+1}\|_2^2 \right) \\ \text{Project } s \text{ onto the feasible set } C \end{cases} \quad (۱۴)$$

قسمت دوم رابطه‌ی ۱۴ به این معنی است که بعد از بهینه‌سازی s ، آن را طوری تغییر دهیم تا فضای k ی آن با محل نمونه‌های برداشته شده از y (چیزی که از دستگاه MRI اخذ کردیم) یکسان باشد. از آن جا که تبدیل wavelet استفاده شده در این مقاله، unitary است، پس به جای z_{k+1} و s می‌توانیم ضرایب تبدیل wavelet آن‌ها را استفاده کنیم (طبق رابطه‌ی ۱۳):

$$\|s - z_{k+1}\|_2^2 = \|\Psi\alpha - \Psi\beta_{k+1}\|_2^2 = \|\alpha - \beta_{k+1}\|_2^2 \quad (۱۵)$$

پس رابطه‌ی ۱۴ را با جای‌گذاری رابطه‌ی ۱۵ در آن و جای‌گذاری $\Psi^{-1}s = \alpha$ ، دوباره می‌نویسیم.

$$\begin{cases} s = \underset{s}{\operatorname{argmin}} \left(\|\alpha\|_{0,\sigma} + \frac{1}{2\lambda_p} \|\alpha - \beta_{k+1}\|_2^2 \right) \\ \text{Project } s \text{ onto the feasible set } C \end{cases} \quad (۱۶)$$

در رابطه‌ی ۱۵، آلفا و بتا، به ترتیب ضرایب تبدیل wavelet s و z هستند. همچنین بخاطر داریم که تبدیل wavelet، یک نمایان‌گر sparse از s یا z به ما می‌دهد.

طبق رابطه‌ی ۲ به یاد داریم که :

$$\|s\|_{0,\sigma} = m - F_\sigma(s) = m - \sum_{i=1}^m \exp\left(-\frac{s_i^2}{2\sigma^2}\right) \approx \|s\|_0 \quad (۲)$$

حال باید گرادیان $E(\alpha) = 1 - \exp\left(-\frac{\alpha}{2\sigma^2}\right) + \frac{1}{2\lambda_p} \|\alpha - \beta_{k+1}\|_2^2$ را حساب کنیم که می‌شود:

$$g(\alpha) = \frac{\partial}{\partial \alpha} E(\alpha) = \frac{\alpha}{\sigma^2} \exp\left(-\frac{\alpha^2}{2\sigma^2}\right) + \frac{1}{\lambda_p} (\alpha - \beta_{k+1}) \quad (۱۷)$$

حال، رابطه‌ی ۱۶ را باز نویسی می‌کنیم. همچنین ضریب آپدیت کردن گرادیان را هم μ فرض می‌کنیم که گاهی به آن نرخ یادگیری هم گفته می‌شود.

$$s_{new} = \Psi\alpha - \mu\Psi g(\alpha) = \Psi\alpha - \mu\Psi \left(\frac{\alpha}{\sigma^2} \sum_{i=1}^m \exp\left(-\frac{\alpha_i^2}{2\sigma^2}\right) + \frac{1}{\lambda_p}(\alpha - \beta_{k+1}) \right) \quad (18)$$

پس درواقع آمادیم و ابتدا تصویر را به فضای wavelet که sparse است بردیم، ضرایب wavelet را به کمک گرادیان، بهینه کردیم و دوباره برگردانیدیم به فضای مکان (با عکس تبدیل wavelet). توجه کنید که Ψ ، عکس تبدیل wavelet است. اکنون قسمت اول رابطه‌ی ۱۴ را تکمیل کردیم (آپدیت کردن گرادیان) حال باید قسمت دوم آن یعنی نگاشت گرادیان را انجام دهیم. از رابطه‌ی ۳ به‌خاطر داریم که $y = A.s = A\Psi\alpha$ ، حال قسمت نگاشت گرادیان را به این ترتیب انجام می‌دهیم.

$$s_{new} = s - A^\dagger(As - y) \quad (19)$$

در این رابطه، $A^\dagger = A^T(AA^T)^{-1}$ در واقع ماتریس شبه معکوس^{۱۸} A می‌باشد. همچنین As ، اندازه‌گیری پیش‌بینی شده از s کنونی است. $As - y$ ، باقی‌مانده در فضای اندازه‌گیری است. توجه داریم که فضای اندازه‌گیری در MRI، همان فضای k می‌باشد. با کسر $A^\dagger(As - y)$ از s ، درواقع s جدید را دوباره به فضای اولیه‌ی تصویر برگردانیم. حال برویم تا رابطه‌ی ۱۹ را باز کرده و ماتریس شبه معکوس A را باز نویسی کنیم.

در روش CS، رابطه‌ی $y=As$ (اندازه‌گیری فضای k در MRI) به صورت زیر نوشته می‌شود.

$$y = As = MFS, \quad y \in R^m, \quad M \in R^{m \times n}, \quad F \in R^{n \times n} \quad (20)$$

در رابطه‌ی ۲۰، y که ابعاد $m \times m$ دارد، تصویر کم‌نمونه‌برداری شده در فضای فرکانس (k -space) است. M ، ماسک کم‌نمونه‌برداری می‌باشد که ابعاد فضای k ی تصویر اصلی را از $n \times n$ به $m \times m$ تغییر می‌دهد، به آن ماسک اندازه‌گیری هم گفته می‌شود. در نهایت، F ، تبدیل فوریه‌ی unitary است که تصویر s را از حوزه‌ی مکان، به حوزه‌ی فرکانس می‌برد. می‌دانیم طبق خواص تبدیل‌های unitary، $F^T F = FF^T = I_{n \times n}$ ، که

¹⁸ pseudo inverse

I ، ماتریس همانی است. همچنین، ماتریس M ، در هر سطر خود فقط یک درایه‌ی غیر صفر دارد و هر جفت سطر آن بر هم عمود^{۱۹} هستند پس طبق خواص ماتریسی، $M^T M = M M^T = I_{m \times m}$. طبق خواصی که نوشته شد، حالا می‌توانیم ماتریس شبه معکوس $A^\dagger$ را باز نویسی کنیم.

$$\begin{aligned} A^\dagger &= A^T (A A^T)^{-1} = (M F)^T (M F (M F)^T)^{-1} = F^T M^T (M F F^T M^T)^{-1} \\ &= F^T M^T (I \times I)^{-1} = F^T M^T \end{aligned} \quad (21)$$

حال، رابطه‌ی ۱۹ را باز نویسی می‌کنیم.

$$s_{new} = s - A^\dagger (A s - y) = F^T M^T (M F s - y) = F^T (M^T M F s - M^T y) \quad (22)$$

می‌دانیم که M ، ماسک نمونه‌برداری بود، پس $M_{n \times m}^T M_{m \times n} F s_{n \times n} = Mask \odot F s$ ، در واقع عمل گر $\odot$ ، ضرب درایه‌به درایه می‌باشد. همچنین $M_{n \times m}^T y_{m \times m} = Mask \odot y = \hat{y}_{n \times n}$ پس رابطه‌ی ۲۲ را باز نویسی می‌کنیم.

$$s_{new} = s - F^T (Mask \odot F s - \hat{y}) \quad (23)$$

همچنین قابل توجه است که در پایتون، حتی تصاویر حوزه‌ی مکان هم به صورت مختلط^{۲۰} هستند زیرا از فضای k ، عکس تبدیل فوریه گرفته شده‌است. البته در بعضی از مراحل مثل نمایش تصاویر نهایی، اندازه‌ی این اعداد مختلط محاسبه شده و به عنوان تصویر حوزه‌ی مکان، نمایش داده می‌شوند.

¹⁹ orthogonal

²⁰ Complex

❖ کد مربوط به کاهش و نگاشت گرادیان:

```
def sl0_gradient_step(s, z_k, sigma_k, lam_p, mu, mask, y_hat,
                     wavelet='haar', level=4):

    """
    gradient decent + projection step (inner loop).
    s, z_k: complex images
    sigma_k: current sigma
    lam_p: penalty lambda
    mu: gradient step size
    mask: undersampling mask (0/1)
    y_hat: zero-padded kspace measurements
    """

    # the function is vectorized over all wavelet coefficients so we dont
    need the  $\sum$  from i to M

    alpha, slices = wavelet_forward(s, wavelet=wavelet, level=level)
    beta, _ = wavelet_forward(z_k, wavelet=wavelet, level=level)

    grad_l0 = np.exp(-alpha**2 / (2.0 * sigma_k**2)) * alpha / (sigma_k**2)

    grad_reg = (alpha - beta) / lam_p
    g_alpha = grad_l0 + grad_reg

    alpha_new = alpha - mu * g_alpha    # the updated wavelet coefficient of
s (alpha)

    s_new = wavelet_inverse(alpha_new, slices, wavelet=wavelet) # lets get
the new s out of the updated alpha

    Fs = fft2c(s_new)    # k-space of current s
    s_proj = s_new - ifft2c(mask * Fs - y_hat)    #y_hat: 0 padded version of
sampled kspace (mask * k_full)
    return s_proj
```

۳-۴-۸- الگوریتم ISRSL0

۳-۴-۸-۱- حلقه‌ی خارجی

الگوریتم ISRSLO از دو حلقه^{۲۱} تشکیل شده است. حلقه خارجی برای کاهش تدریجی پارامتر σ طراحی شده تا از به دام افتادن در مینیمم محلی جلوگیری کند. حلقه خارجی تا زمانی که σ به آخرین مقدار خود (کوچک‌ترین) نرسیده باشد، ادامه می‌یابد. پس برای شروع الگوریتم، باید یک دنباله‌ی نزولی از σ مشخص کنیم. عملیات denoising و تیزسازی در این حلقه انجام می‌شود.

۲-۸-۴-۳- حلقه‌ی داخلی

در حلقه‌ی داخلی کاهش و نگاشت گرادیان انجام می‌شود. هدف حلقه داخلی کمینه کردن تابع هزینه $\|\Psi^{-1}s\|_{0,\sigma} + \frac{1}{2\lambda_p}\|s - z_{k+1}\|_2^2$ (رابطه‌ی ۱۴) برای یک σ مشخص است. حلقه‌ی داخلی برای دو دفعه تکرار می‌شود و همگرایی دقیق در این حلقه الزامی نیست. شکل ۴-۵، مراحل کامل الگوریتم ISRSLO را نشان می‌دهد.

Algorithm 1: ISRSLO

Input: observation vector $\mathbf{y}$, sampling pattern **Mask**, penalty parameter λ_p , gradient descent parameter μ

Initialization:

- $\mathbf{s}_0 = \mathbf{A}^\dagger \mathbf{y} = \mathbf{F}^T \mathbf{M}^T$
 - Choose a suitable decreasing sequence, $[\sigma_1, \dots, \sigma_K]$.
 - $g(k) = \frac{0.08}{\text{Sampling Rate}\%} \times \sigma_k$
-

For $k = 1, \dots, K$

■ Denoising: $\mathbf{z}_k = D(\mathbf{s}_{k-1}, g(k))$

■ Sharpening:

$$1) \text{ } SR = 1 - \left| \frac{3\sigma_p q + v}{2\sigma_p^2 + 2\sigma_q^2 + v} \right|$$

$$2) \text{ } \mathbf{z}_k = \mathbf{z}_k + SR \otimes ((0.8)^k \cdot \mathbf{s}_{k-1})$$

■ $\mathbf{s} = \mathbf{s}_{k-1}$

■ Minimizing $\|\Psi^{-1}\mathbf{s}\|_{0,\sigma} + \frac{1}{2\lambda_p}\|\mathbf{s} - \mathbf{z}_{k+1}\|_2^2 + \delta_c(\mathbf{s})$ using L iterations of the gradient descent and projection on the feasible subspace C :

● **For** $j = 1, \dots, L$

$$1) \text{ } \boldsymbol{\alpha} = \Psi \mathbf{s}$$

$$2) \text{ } \boldsymbol{\beta}_k = \Psi \mathbf{z}_k$$

$$3) \text{ Gradient descent: } \mathbf{s} \leftarrow \Psi \boldsymbol{\alpha} - \mu \Psi \left(\sum_{i=1}^M \exp\left(\frac{-\alpha_i^2}{2\sigma_k^2}\right) + \frac{1}{\lambda_p}(\boldsymbol{\alpha} - \boldsymbol{\beta}_k) \right)$$

4) Projection into the feasible subspace C

$$\mathbf{s} \leftarrow \mathbf{s} - \mathbf{F}^T (\text{Mask} \odot \mathbf{F} \mathbf{s} - \mathbf{\hat{y}})$$

● **End For**

■ $\mathbf{s}_k = \mathbf{s}$

End For

²¹ Loop

شکل ۴-۴- مراحل کامل الگوریتم *ISRSLO*

نکته‌ای بسیار مهم این است که در این شکل یک اشتباه فجیع تایپی وجود دارد. دقیقاً خط سوم حلقه‌ی داخلی، گرادیان نرم صفر آلفا را به اشتباه حساب کرده و به اشتباه مشتق گرفته است و ترم $\frac{\alpha}{\sigma^2}$ را جا انداخته است. شکل درست آن در رابطه‌ی ۱۸ آمده است. صرفاً برای مقایسه، رابطه‌ی ۱۸ را دوباره در ادامه آوردم.

$$s_{new} = \Psi\alpha - \mu\Psi g(\alpha) = \Psi\alpha - \mu\Psi \left(\frac{\alpha}{\sigma^2} \sum_{i=1}^m \exp\left(-\frac{\alpha_i^2}{2\sigma^2}\right) + \frac{1}{\lambda_p}(\alpha - \beta_{k+1}) \right) \quad (18)$$

۳-۴-۹- تحلیل و اثبات هم‌گرایی

می‌دانیم طبق رابطه‌ی ۷،

$$J_k = J_p^{HQS}(s_k, z_k) = \|\Psi^{-1}s\|_{0,\sigma} + \lambda_{s_k} \cdot \text{smoothness}(z) + \delta_c(s) + \frac{1}{2\lambda_p} |s_k - z_k|_2^2$$

حال:

$$\begin{aligned} J_k - J_{k+1} &= J_p^{HQS}(s_k, z_k) - J_p^{HQS}(s_{k+1}, z_{k+1}) \\ &= (J_p^{HQS}(s_k, z_{k+1}) - J_p^{HQS}(s_{k+1}, z_{k+1})) + (J_p^{HQS}(s_k, z_k) - J_p^{HQS}(s_k, z_{k+1})) \end{aligned} \quad (24)$$

می‌دانیم که $J_p^{HQS}(s_k, z_k) < J_p^{HQS}(s_k, z_{k+1})$ و $J_p^{HQS}(s_{k+1}, z_{k+1}) < J_p^{HQS}(s_k, z_{k+1})$ پس، حاصل $J_k - J_{k+1}$ همواره نامنفی است و لذا J_p^{HQS} همگرا است.

همچنین رابطه‌ی denoiser را به خاطر داریم $\sigma_k = \frac{0.08}{\text{Sampling rate \%}} \times \sigma_k$ می‌دانیم که اگر سیگما خیلی کوچک باشد، $g(k)$ هم کوچک است و لذا $s_k \sim z_{k+1}$ پس:

$$J_p^{HQS}(s_{k+1}, z_{k+1}) \cong J_p^{HQS}(s_{k+1}, s_{k+1}) \quad (25)$$

حال همگرایی الگوریتم ISRLS0 را اثبات می‌کنیم.

$$\begin{aligned} J_{ISRLS0}(s_k) &= J_p^{HQS}(s_k, z_k) > J_p^{HQS}(s_k, z_{k+1}) > J_p^{HQS}(s_{k+1}, z_{k+1}) \cong J_p^{HQS}(s_{k+1}, s_{k+1}) \\ &= J_{ISRLS0}(s_{k+1}) \quad \rightarrow \quad J_{ISRLS0}(s_k) > J_{ISRLS0}(s_{k+1}) \end{aligned} \quad (26)$$

پس تابع الگوریتم ISRL0 با هر iteration، کاهش می‌یابد. این قضیه، همگرایی این روش را نشان می‌دهد اما همگرایی global را تضمین نمی‌کند و ممکن است الگوریتم به یک مینیموم محلی همگرا شود چراکه نرم 10، غیر محدب است.

۳-۴-۱۰- ماسک‌های نمونه‌برداری

در این مقاله به سه ماسک نمونه‌برداری معروف یعنی کارتزین^{۲۲}، مارپیچی^{۲۳} و شبه دایروی^{۲۴} اشاره شده است. با توجه به این که فضای k تصاویر MRI، یکنواخت نیست، استفاده از ماسک‌های نمونه‌برداری یکنواخت انتخاب مناسبی نیست. چون در محدوده‌ی فرکانس صفر، مولفه‌های بیشتری موجود است، ماسک مربوطه نیز باید این نواحی رو بیشتر نمونه برداری کند. در مقاله، تمرکز بر روی ماسک شبه دایروی بوده است. بنده در این پژوهش، علاوه بر این سه ماسک، از سه ماسک دیگر نیز استفاده کردم یعنی ماسک مربعی، تصادفی و کارتزین افقی/عمودی.


²² Cartesian

²³ Spiral

²⁴ Pseudo-Radial

۳-۴-۱۰-۱- پیاده‌سازی ماسک‌ها در پایتون


شکل ۴-۵، یک نمونه تصویر MRI زانو و مغز از دیتاست fastMRI را نشان می‌دهد. همچنین این نکته قابل توجه است که طبق مقاله، تصاویر استفاده شده در پژوهش، ابتدا از ابعاد 320×320 به 256×256 تبدیل شده‌اند.



شکل ۴-۵- یک نمونه تصویر MRI زانو و مغز به همراه فضای k ی کامل آن


حال در ادامه، به بررسی اثر ماسک‌های مختلف روی این تصویر نمونه می‌پردازیم. ماسک‌های باینری به همراه یک پارامتر درصد پوشش تعریف می‌شوند که میزان پوشش فضای k را نشان می‌دهد. کدهای مربوطه در فایل جویپتر موجود هستند، به دلیل طولانی‌تر نشدن گزارش، کدهای این بخش را در گزارش نیاوردم.

شکل ۴-۶، نتیجه‌ی اعمال ماسک مربعی ۱۰ درصد را روی تصویر نمونه‌ی زانو و مغز نشان می‌دهد. می‌بینیم که تصویر مقداری تار شده است.




شکل ۴-۶- نتیجه‌ی اعمال ماسک مربعی ۱۰ درصد روی یک نمونه تصویر *MRI* زانو و مغز

شکل ۴-۷ نتیجه‌ی اعمال ماسک کارتزین افقی ۱۰ درصد را روی تصویر نمونه‌ی زانو و مغز نشان می‌دهد. می‌بینیم که تصویر دچار تاری در راستای عمودی شده است.




شکل ۴-۷- نتیجه‌ی اعمال ماسک کارتزین افقی ۱۰ درصد روی یک نمونه تصویر *MRI* زانو و مغز

شکل ۴-۸- نتیجه‌ی اعمال ماسک کارتزین عمودی ۱۰ درصد را روی تصویر نمونه‌ی زانو و مغز نشان می‌دهد. می‌بینیم که تصویر دچار تاری در راستای عمودی شده است.




شکل ۴-۸- نتیجه‌ی اعمال ماسک کارتیزین عمودی ۱۰ درصد روی یک نمونه تصویر *MRI* زانو و مغز

شکل ۴-۹- نتیجه‌ی اعمال ماسک شبه دایروی ۱۰ درصد را روی تصویر نمونه‌ی زانو و مغز نشان می‌دهد. می‌بینیم که تصویر دچار تارری نسبتاً تصادفی و یکنواخت شده است. همچنین الگوهای مشابه ماسک در تصویر قابل مشاهده است.




شکل ۴-۹- نتیجه‌ی اعمال ماسک شبه دایروی ۱۰ درصد روی یک نمونه تصویر *MRI* زانو و مغز

شکل ۴-۱۰ نتیجه‌ی اعمال ماسک مارپیچی ۱۰ درصد را روی تصویر نمونه‌ی زانو و مغز نشان می‌دهد. ماسک به نحوی طراحی شده تا در مرکز، نمونه‌های بیشتری اخذ کند. مشاهده می‌شود که یک الگوی مارپیچی به صورت نویز در تصویر بازسازی شده‌ی مغزی مشاهده می‌شود.




شکل ۴-۱۰- نتیجه‌ی اعمال ماسک شبه دایروی ۱۰ درصد روی یک نمونه تصویر *MRI* زانو و مغز

شکل ۴-۱۱- نتیجه‌ی اعمال ماسک تصادفی ۱۰ درصد را روی تصویر نمونه‌ی زانو و مغز نشان می‌دهد. مشاهده می‌شود که هیچ جزئیاتی از تصویر قابل مشاهده نیست.




شکل ۴-۱۱- نتیجه‌ی اعمال ماسک تصادفی ۱۰ درصد روی یک نمونه تصویر *MRI* زانو و مغز

شکل ۴-۱۲- نتیجه‌ی اعمال ماسک تصادفی با چگالی متغیر ۱۰ درصد را روی تصویر نمونه‌ی زانو و مغز نشان می‌دهد. مشاهده می‌شود که این ماسک نسبت به ماسک تصادفی یک نواخت، آناتومی را بهتر نشان می‌دهد.



شکل ۴-۱۲- نتیجه‌ی اعمال ماسک تصادفی با چگالی متغیر ۱۰ درصد روی یک نمونه تصویر *MRI* زانو و مغز

همچنین می‌توان کلیه‌ی این ماسک‌ها را برای درصد نمونه‌برداری‌های مختلف نمایش داد. برای مثال شکل ۴-۱۳، ماسک شبه دایروی را برای ۴ نرخ نمونه برداری مختلف نشان می‌دهد.



شکل ۴-۱۳- ماسک شبه دایروی با نرخ‌های نمونه‌برداری مختلف

۳-۵- معیارهای ارزیابی روش

برای ارزیابی تصاویر بازسازی شده از سه معیار پیک نسبت سیگنال به نویز^{۲۵} (PSNR)، نرم خطای فرکانس بالا^{۲۶} (HFEN) و ضریب شباهت ساختاری^{۲۷} (SSIM) استفاده شده است. توابع آماده‌ی محاسبه‌ی PSNR و SSIM در کتابخانه‌ی skimage.metrics موجود می‌باشند. بنده از همان توابع آماده استفاده کردم.

۳-۵-۱- PSNR

رابطه‌ی ۲۷، نحوه‌ی محاسبه‌ی PSNR را نشان می‌دهد. در این رابطه، MSE، درواقع مربعات حداقل خطای بین تصویر اصلی و بازسازی شده را نشان می‌دهد. همچنین ۲۵۵ هم به این دلیل استفاده شده است که سائز تصاویر ۲۵۶×۲۵۶ هستند.

$$PSNR = 10 \log_{10} \left(\frac{255^2}{MSE(x, \hat{x})} \right) \quad (27)$$

۳-۵-۲- HFEN

رابطه‌ی ۲۸، نحوه‌ی محاسبه‌ی HFEN را نشان می‌دهد. H_{HIGH} ، درواقع یک فیلتر بالاگذر گوسین است. متأسفانه در مقاله ذکر نشده که این فیلتر چه فرکانس قطعی باید داشته باشد! برای همین نتایج ارزیابی پیاده‌سازی بنده با استفاده از این معیار، با مقاله متفاوت است و به دلیل فرکانس قطع، بایاس دارد. من در پیاده‌سازی ام، سیگمای فیلتر بالاگذر را 0.35 فرض کردم.

$$HFEN = H_{HIGH}(x) - H_{HIGH}(\hat{x}) \quad (28)$$

²⁵ Peak Signal to Noise Ratio

²⁶ High-Frequency Error Norm

²⁷ Structural Similarity Index

SSIM - ۳-۵-۳

رابطه‌ی ۲۹، نحوه‌ی محاسبه‌ی معیار SSIM را نشان می‌دهد که درواقع درصد شباهت ساختاری دو تصویر را نشان می‌دهد.

$$SSIM = \frac{(2\mu_x\mu_{\hat{x}} + c_1)(2\sigma_{x\hat{x}} + c_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + c_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + c_2)} \quad (29)$$


۳-۶- دادگان پژوهش

دادگانی که برای بررسی الگوریتم در این مقاله استفاده شدند، تصاویر زانو و مغز از پایگاه داده‌ی [fastMRI](#) بودند. پایگاه داده fastMRI، ابتکار مشترک NYU Langone Health و Meta AI (FAIR)، یکی از جامع‌ترین مجموعه‌های داده‌ی عمومی برای بازسازی MRI است. این پایگاه شامل بیش از ۱۵۰۰ تصویر multicoil زانو و ۷۰۰۰ تصویر مغز در فرمت فضای k به همراه تصاویر DICOM می‌باشد. همچنین شدت میدان مغناطیسی دستگاه‌های استفاده شده ۱.۵ و ۳T بوده است.

۳-۶-۱- تصاویر زانو

در این مقاله، از ۲۰ تصویر زانو از سری single-coil validation انتخاب شده است. همچنین تصاویر، ابتدا از اندازه‌ی ۳۲۰ در ۳۲۰ به ۲۵۶ در ۲۵۶ کاهش سایز پیدا کرده اند. در این سری از داده‌ها ۱۹۹ تصویر زانو وجود دارد. این که از کدام تصاویر برای ارزیابی مدل استفاده شده است، مشخص نیست و نکته‌ی جالب این است که بعضی از تصاویر دقت بالاتری در مدل دارند و بعضی دقت‌های بسیار کم. می‌شود ۲۰ تا از بهترین‌ها را انتخاب نمود تا به دقت بالا و کاذبی دست یافت!

بنده از همه‌ی ۱۹۹ تصویر موجود برای ارزیابی کدهایم استفاده کردم. همچنین در مقاله ذکر نشده بود که از کدام slice تصاویر، استفاده شده، بنده طبق مرور ادبیات، از اسلایس میانی استفاده کردم. شکل ۴-۱۴، تصویر ایمیل دریافت شده از طرف پایگاه fastMRI را نشان می‌دهد که حاوی لینک‌های دانلود دیتاست‌ها می‌باشد.




شکل ۴-۱۴- ایمیل حاوی لینک دانلود داده‌های زانو پایگاه *fastMRI*

داده‌های دانلود شده با فرمت h5 هستند. درون آن‌ها یک بخش مربوط به header فایل موجود است که حاوی پارامترهای اسکن مثل FOV، زمان استراحت و زمان اکو است. بخش دیگری به نام kspace وجود دارد که حاوی داده‌ی خام فضای k است (سایز 320×320). ۲ بخش دیگر با نام‌های **reconstruction_esc** و **reconstruction_rss** که به ترتیب حاوی تصاویر حوزه‌ی مکانی بازسازی شده با روش ESPIRiT و روش جذر مجموع مربعات^{۲۸} است که داده‌ی دوم معمولاً به عنوان داده‌ی ground truth استفاده می‌شود.

```
singlecoil = h5py.File(file_path)
print('Keys:', list(singlecoil.keys()))
Keys: ['ismrmrd_header', 'kspace', 'reconstruction_esc',
'reconstruction_rss']
```

فضای kی خام این تصاویر، اندازه‌ی 35×368×640 دارد که شکل ۴-۱۵ یکی از ۳۵ اسلایس آن را نمایش نشان می‌دهد.

²⁸ Root of Sum of Squares



شکل ۴-۱۵- فضای خام یک تصویر زانو از پایگاه *fastMRI*

برای پیاده‌سازی، من ابتدا اسلایس میانی تصاویر بازسازی شده‌ی مرجع با سایز 320×320 را به اندازه‌ی 256×256 کاهش سایز دادم، سپس به فضای k بردم و آن دیتا را به عنوان ورودی مدل در نظر گرفتم. ❖ کد مربوط به خواندن و کاهش سایز تصاویر زانو:

```
# ----- Load knee slice and resize k-space to 256x256 -----
def load_rss_image_kspace_256(h5_path, slice_index='middle'):
    with h5py.File(h5_path, 'r') as f:
        rss = f['reconstruction_rss'][:] # [nslices, ny, nx]
        nslices, ny, nx = rss.shape

        if slice_index == 'middle':
            si = nslices // 2
        else:
            si = int(slice_index)

        img = rss[si].astype(float)

        # resize image to 256x256
        img_res = resize(img, (256, 256), anti_aliasing=True)

        # k-space of this resized image
        k_res = fft2c(img_res)
        return img_res, k_res
```

۳-۶-۲- تصاویر مغز

صرفاً در مقاله گفته شده است که از ۱۰ تصویر مغزی برای ارزیابی مدل استفاده شده است! من فرض را بر این گرفتم که همچنان از سری داده‌های validation استفاده شده بود. تصاویر مغزی، multicoil بودند و سه سری داده با حجم حدود ۹۰ گیگ برای دانلود موجود بود. بنده سری اول آن‌ها را با عنوان [brain_multicoil_val_batch_0](#) (~93.5 GB) دانلود کردم.

بر خلاف دادگان زانو، تصاویر مغزی، multicoil بودند. در واقع یک تصویر multicoil یعنی اینکه همزمان، چندین کوئل RF، اخذ تصویر می‌کنند و لذا فرایند تصویربرداری سریع‌تر می‌شود. ابعاد تصاویر فضای kی مغزی (16, 16, 640, 320) می‌باشند که اعداد از چپ به راست، تعداد اسلایس، تعداد کوئل، ابعاد عمودی و ابعاد افقی تصویر را نشان می‌دهد. برای استفاده از تصاویر مغز در آنالیز هم مثل روش تصاویر زانو عمل می‌کنیم و از تصویر حوزه‌ی مکانی (با پسوند reconstruction_rss) استفاده می‌کنیم. این تصویر ابعاد 320×320 دارد & آن را پس از کاهش سایز به ۲۵۶×۲۵۶، به حوزه‌ی فوریه می‌بریم و به عنوان ورودی مدل استفاده می‌کنیم.

۳-۶-۲-۱- کنتراست‌های مختلف

در فایل دانلود شده، ۴ سری تصویر با کنتراست‌های مختلف وجود داشت.

1. T1. (۲۰ تصویر)

2. T2. (۲۵۶)

3. Flair. (۲۱ تصویر)

4. T1-post. (اخذ تصویر بعد از تزریق ماده‌ی حاجب) (۱۰۶ تصویر)

۳-۷- نتایج مقاله

۳-۷-۱- اثر ماسک‌های نمونه‌برداری

پیش‌تر در مقاله گفته شده بود که بهترین ماسک، ماسک شبه دایروی بوده است! اما الان گفتند که ماسک تصادفی ۲ بعدی بهترین عملکرد را داشته است. نکته‌ی جالب این است که اصلاً از این نوع ماسک، در بخش مواد و روش‌ها صحبت نشده بود.

Sampling pattern	SFISA	PFISTA	FDLCP	ISRL0-BM3D
2D Random	35.12	35.11	35.70	36.01
Cartesian	30.20	30.20	30.54	32.61
Radial	34.89	34.88	35.31	35.97

شکل ۴-۱۶: مقایسه‌ی دقت روش ISRL0 برای ماسک‌های مختلف

در ادامه به بررسی عددی نتایج پرداخته می‌شود.

۳-۷-۲- نتایج بازسازی تصاویر زانو

جدول ۴-۲، نتایج روش‌های SL0، ISRL0 با denoiser BM3D و ISRL0 با Weiner Denoiser را نشان می‌دهد. مشاهده می‌شود که روش ISRL0 با denoiser BM3D بالاترین دقت را دارد. همچنین در این جدول، سایر روش‌های CS نیز مقایسه شده‌اند اما آیا روی همین تصاویری که در این مقاله استفاده شده کار کردند؟! خدا میداند 😊

توجه: روش SL0 درواقع همان روش ISRL0 است که فرایندهای denoising و تیزسازی حذف شده و لذا دیگر تبدیل wavelet هم در آن وجود ندارد و صرفاً تابع نرم SL0 را به کمک گرادیان، بهینه می‌کند.

Method	Mask 10%			Mask 20%			Mask 30%			Mask 50%		
	PSNR (SD)	HFEN (SD)	SSIM (SD)	PSNR (SD)	HFEN (SD)	SSIM (SD)	PSNR (SD)	HFEN (SD)	SSIM (SD)	PSNR (SD)	HFEN (SD)	SSIM (SD)
IFR-Net	29.23 (1.68)	1.65 (0.14)	0.71 (0.13)	32.37 (2.1)	0.92 (0.11)	0.80 (0.15)	35.93 (2.41)	0.30 (0.06)	0.89 (0.17)	36.45 (2.8)	0.23 (0.04)	0.90 (0.18)
FDLCP	29.20 (1.82)	1.55 (0.15)	0.32 (0.21)	32.12 (2.5)	0.89 (0.11)	0.45 (0.16)	35.31 (2.6)	0.32 (0.07)	0.69 (0.178)	35.99 (2.73)	0.24 (0.041)	0.71 (0.2)
KTMR	29.01 (1.71)	1.7 (0.16)	0.68 (0.19)	32.15 (2.48)	0.95 (0.112)	0.79 (0.16)	35.54 (2.61)	0.32 (0.075)	0.87 (0.169)	36.10 (2.78)	0.24 (0.043)	0.89 (0.2)
PFISTA	28.03 (3.49)	1.89 (0.2)	0.31 (0.22)	31.72 (3.75)	1.07 (0.15)	0.45 (0.24)	34.88 (3.9)	0.43 (0.068)	0.63 (0.26)	36.09 (4.55)	0.26 (0.077)	0.71 (0.29)
SFISTA	28.11 (3.52)	1.8 (0.21)	0.31 (0.22)	31.74 (3.76)	1.07 (0.19)	0.45 (0.25)	34.89 (3.95)	0.43 (0.1)	0.63 (0.28)	36.10 (4.5)	0.25 (0.087)	0.71 (0.29)
SL0	26.22 (3.54)	2.27 (0.19)	0.55 (0.22)	30.10 (3.01)	1.5 (0.15)	0.71 (0.24)	34.75 (3.48)	0.43 (0.1)	0.86 (0.26)	35.14 (3.7)	0.32 (0.075)	0.87 (0.29)
ISRSL0-Wiener	28.37 (1.32)	1.8 (0.132)	0.68 (0.12)	31.74 (1.78)	1.03 (0.10)	0.78 (0.14)	35.66 (1.84)	0.32 (0.96)	0.89 (0.145)	36.23 (2.01)	0.26 (0.041)	0.90 (0.15)
ISRSL0-BM3D	29.30 (0.97)	1.55 (0.12)	0.73 (0.09)	32.47 (1.12)	0.87 (0.098)	0.80 (0.1)	35.97 (1.2)	0.29 (0.055)	0.89 (0.12)	36.56 (1.27)	0.24 (0.039)	0.90 (0.12)

شکل ۴-۱۷: مقایسه‌ی دقت روش *ISRSL0* برای تصاویر زانو و ماسک‌های مختلف و نرخ نمونه برداری های مختلف

طبق شکل ۴-۱۷ مشاهده می‌شود که با افزایش درصد نمونه‌برداری، شباهت تصویر بازسازی شده با تصویر اصلی بیشتر می‌شود ولی از ۳۰ درصد تا ۵۰ درصد، دیگر تفاوت چندانی نمی‌کند.

۳-۷-۳- نتایج بازسازی تصاویر مغز

شکل ۴-۱۷، نتایج روش *ISRSL0* را برای تصاویر مغزی نشان می‌دهد.

Method	Mask 10%			Mask 20%			Mask 30%			Mask 50%		
	PSNR (SD)	HFEN (SD)	SSIM (SD)	PSNR (SD)	HFEN (SD)	SSIM (SD)	PSNR (SD)	HFEN (SD)	SSIM (SD)	PSNR (SD)	HFEN (SD)	SSIM (SD)
IFR-Net	25.60 (1.21)	2.71 (0.2)	0.67 (0.14)	31.01 (1.45)	1.28 (0.13)	0.85 (0.165)	36.48 (2.16)	0.30 (0.1)	0.94 (0.18)	37.68 (3.1)	0.23 (0.06)	0.96 (0.18)
FDLCP	25.35 (1.42)	2.8 (0.24)	0.40 (0.18)	30.9 (2.06)	1.32 (0.2)	0.64 (0.191)	36.23 (2.46)	0.31 (0.12)	0.82 (0.198)	37.10 (3.4)	0.23 (0.062)	0.83 (0.2)
KTMR	25.40 (1.4)	2.85 (0.23)	0.64 (0.17)	30.91 (2.1)	1.25 (0.181)	0.79 (0.177)	36.33 (2.40)	0.30 (0.115)	0.89 (0.0183)	37.20 (3.4)	0.24 (0.064)	0.90 (0.19)
PFISTA	24.45 (3.28)	3.20 (0.35)	0.34 (0.19)	29.05 (3.35)	1.8 (0.29)	0.55 (0.19)	34.87 (3.93)	0.56 (0.21)	0.79 (0.25)	36.69 (4.8)	0.30 (0.1)	0.83 (0.28)
SFISTA	24.50 (3.3)	3.17 (0.38)	0.35 (0.19)	29.08 (3.2)	1.8 (0.29)	0.58 (0.2)	34.89 (3.87)	0.54 (0.2)	0.8 (0.25)	36.70 (5.1)	0.29 (0.11)	0.83 (0.3)
SL0	22.96 (2.98)	3.71 (0.3)	0.48 (0.2)	26.70 (2.95)	2.55 (0.27)	0.66 (0.21)	32.98 (3.54)	0.6 (0.2)	0.89 (0.23)	34.43 (4.1)	0.46 (0.095)	0.91 (0.24)
ISRSL0-Wiener	24.70 (1.2)	3.03 (0.18)	0.62 (0.16)	29.40 (1.58)	1.67 (0.13)	0.81 (0.17)	35.65 (1.71)	0.37 (0.075)	0.94 (0.178)	36.87 (1.96)	0.3 (0.05)	0.96 (0.187)
ISRSL0-BM3D	25.70 (0.76)	2.63 (0.174)	0.67 (0.1)	31.06 (1.03)	1.19 (0.097)	0.86 (0.15)	36.81 (1.27)	0.3 (0.06)	0.95 (0.112)	37.80 (1.26)	0.23 (0.04)	0.96 (0.12)

شکل ۴-۱۸: مقایسه‌ی دقت روش *ISRSL0* برای تصاویر مغز و ماسک‌های مختلف و نرخ نمونه برداری های مختلف

۳-۷-۴- مقایسه‌ی زمان محاسبات روش‌های مختلف

طبق شکل ۴-۱۹، روش *ISRSL0-Weiner*، نسبتاً سریع عمل کرده و از رقبای خود سریع‌تر بوده است. همچنین نسبت زمان این روش نسبت به *ISRSL0-BM3D*، در پیاده‌سازی بنده هم به همین شکل بود.

Method	Computation Time (s)
KTMR	108
FDLCP	64
PFISTA	35
SFISTA	43
IFR-Net	6
SL0	7
ISRSL0-Wiener	11
ISRSL0-BM3D	106

شکل ۴-۱۹: مقایسه‌ی زمان محاسباتی روش *ISRSL0* با سایر روش‌های رایج که در مقاله صرفاً در حد یک جمله به

آنها اشاره شده بود

۳-۸- نتایج پیاده‌سازی من


۳-۸-۱- نتایج بازسازی تصاویر زانو

SUMMARY TABLE: Mean $\pm$ Std (n=199 subjects)				
Sampling Rate	Method	PSNR (mean $\pm$ std)	HFEN (mean $\pm$ std)	SSIM (mean $\pm$ std)
SR=0.1	ISRSL0_wiener	26.42 $\pm$ 2.70	0.288 $\pm$ 0.074	0.731 $\pm$ 0.054
SR=0.1	ISRSL0_BM3D	25.22 $\pm$ 2.95	0.272 $\pm$ 0.072	0.721 $\pm$ 0.062
SR=0.1	SL0	22.91 $\pm$ 3.13	0.285 $\pm$ 0.070	0.619 $\pm$ 0.056
SR=0.1	Zero-filled	22.38 $\pm$ 3.33	0.285 $\pm$ 0.070	0.613 $\pm$ 0.058
SR=0.2	ISRSL0_wiener	32.18 $\pm$ 2.97	0.268 $\pm$ 0.071	0.848 $\pm$ 0.053
SR=0.2	ISRSL0_BM3D	31.10 $\pm$ 3.31	0.252 $\pm$ 0.074	0.822 $\pm$ 0.060
SR=0.2	SL0	28.09 $\pm$ 3.27	0.270 $\pm$ 0.067	0.743 $\pm$ 0.049
SR=0.2	Zero-filled	27.56 $\pm$ 3.57	0.271 $\pm$ 0.067	0.739 $\pm$ 0.051
SR=0.3	ISRSL0_wiener	34.31 $\pm$ 3.14	0.243 $\pm$ 0.066	0.893 $\pm$ 0.044
SR=0.3	ISRSL0_BM3D	33.86 $\pm$ 3.43	0.236 $\pm$ 0.071	0.881 $\pm$ 0.049
SR=0.3	SL0	31.14 $\pm$ 3.21	0.255 $\pm$ 0.063	0.825 $\pm$ 0.040
SR=0.3	Zero-filled	30.63 $\pm$ 3.59	0.255 $\pm$ 0.064	0.822 $\pm$ 0.041
SR=0.5	ISRSL0_wiener	37.84 $\pm$ 3.15	0.199 $\pm$ 0.057	0.939 $\pm$ 0.029
SR=0.5	ISRSL0_BM3D	37.48 $\pm$ 3.60	0.198 $\pm$ 0.062	0.934 $\pm$ 0.033
SR=0.5	SL0	35.23 $\pm$ 2.76	0.217 $\pm$ 0.054	0.907 $\pm$ 0.025
SR=0.5	Zero-filled	34.79 $\pm$ 3.24	0.217 $\pm$ 0.055	0.906 $\pm$ 0.026

شکل ۴-۲۰: نتایج پیاده‌سازی بنده برای ۱۹۹ تصویر زانو با استفاده از روش‌های مختلف ($SL0$ ، $zero-filling$)

($Wiener-ISRSL0$ ، $ISRSL0-BM3D$) و نرخ نمونه برداری‌های مختلف

۳-۸-۱-۱- یک نمونه تصویر بازسازی شده



شکل ۴-۲۱: مقایسه‌ی بازسازی یک نمونه تصویر زانو با استفاده از روش‌های مختلف ($SL0$ ، $zero-filling$)

($Wiener-ISRSL0$ ، $ISRSL0-BM3D$) و نرخ نمونه برداری ۲۰ درصد و ماسک شبه دایروی


۳-۸-۲- نتایج بازسازی تصاویر مغز

SUMMARY TABLE: Mean $\pm$ Std (n=106 subjects)				
Sampling Rate	Method	PSNR (mean $\pm$ std)	HFEN (mean $\pm$ std)	SSIM (mean $\pm$ std)
SR=0.1	ISRSL0_wiener	22.77 $\pm$ 1.76	0.295 $\pm$ 0.039	0.644 $\pm$ 0.050
SR=0.1	ISRSL0_BM3D	21.77 $\pm$ 1.86	0.259 $\pm$ 0.038	0.609 $\pm$ 0.059
SR=0.1	SL0	19.80 $\pm$ 1.76	0.311 $\pm$ 0.040	0.471 $\pm$ 0.053
SR=0.1	Zero-filled	19.72 $\pm$ 1.76	0.311 $\pm$ 0.040	0.470 $\pm$ 0.053
SR=0.2	ISRSL0_wiener	28.68 $\pm$ 2.38	0.243 $\pm$ 0.035	0.828 $\pm$ 0.041
SR=0.2	ISRSL0_BM3D	27.78 $\pm$ 2.09	0.206 $\pm$ 0.032	0.772 $\pm$ 0.047
SR=0.2	SL0	25.36 $\pm$ 2.10	0.284 $\pm$ 0.038	0.648 $\pm$ 0.050
SR=0.2	Zero-filled	25.26 $\pm$ 2.11	0.284 $\pm$ 0.038	0.647 $\pm$ 0.050
SR=0.3	ISRSL0_wiener	32.84 $\pm$ 3.08	0.198 $\pm$ 0.033	0.913 $\pm$ 0.031
SR=0.3	ISRSL0_BM3D	32.08 $\pm$ 2.70	0.172 $\pm$ 0.030	0.867 $\pm$ 0.040
SR=0.3	SL0	28.68 $\pm$ 2.32	0.257 $\pm$ 0.036	0.759 $\pm$ 0.040
SR=0.3	Zero-filled	28.57 $\pm$ 2.34	0.257 $\pm$ 0.036	0.758 $\pm$ 0.041
SR=0.5	ISRSL0_wiener	39.30 $\pm$ 3.15	0.141 $\pm$ 0.028	0.966 $\pm$ 0.015
SR=0.5	ISRSL0_BM3D	37.97 $\pm$ 3.43	0.128 $\pm$ 0.027	0.942 $\pm$ 0.027
SR=0.5	SL0	33.04 $\pm$ 2.21	0.209 $\pm$ 0.030	0.872 $\pm$ 0.025
SR=0.5	Zero-filled	32.89 $\pm$ 2.25	0.209 $\pm$ 0.030	0.871 $\pm$ 0.025

شکل ۴-۲۲: نتایج پیاده‌سازی بنده برای ۱۰۶ تصویر مغز با استفاده از روش‌های مختلف ($SL0$ ، $zero-filling$)

($Wiener-ISRSL0$ ، $ISRSL0-BM3D$) و نرخ نمونه برداری‌های مختلف

۳-۸-۲-۱- یک نمونه تصویر بازسازی شده



شکل ۴-۲۳: مقایسه‌ی بازسازی یک نمونه تصویر مغز با استفاده از روش‌های مختلف ($zero-filling$, $SL0$)

$Wiener-ISRSL0$, $ISRSL0-BM3D$ و نرخ نمونه برداری ۲۰ درصد و ماسک شبه دایروی

مشاهده می‌شود که دقت روش wiener نسبت به بقیه بهتر بوده است.

۳-۹- جمع‌بندی

در مقاله، روش BM3D بالاترین امتیاز را داشت.

✓ Paper's best results: (knee)			✓ Paper's best results: (Brain)		
Sampling Rate	PSNR (mean±std)	SSIM (mean±std)	Sampling Rate	PSNR (mean±std)	SSIM (mean±std)
Mask 10%	29.30 ± 0.97	0.73 ± 0.09	Mask 10%	27.70 ± 0.76	0.67 ± 0.09
Mask 20%	32.47 ± 1.12	0.80 ± 0.041	Mask 20%	31.06 ± 1.03	0.86 ± 0.15
Mask 30%	36 ± 1.8	0.89 ± 0.031	Mask 30%	36.81 ± 1.1	0.95 ± 0.11
Mask 50%	36.8 ± 1.26	0.90 ± 0.12	Mask 50%	37.8 ± 1.26	0.96 ± 0.12

شکل ۴-۲۴: مقایسه‌ی میانگین دقت روش بنده با بهترین نتایج مقاله برای تصاویر زانو

در پیاده‌سازی بنده، روش Wiener دقت بیشتری داشته و می‌بینیم که در تصاویر زانو، با اینکه من روی ۱۹۹ تصویر مدل را اجرا کردم، باز هم دقت بهتری از مقاله گرفتم (فقط روی ۲۰ داده اجرا شده بود)

✓ My best results: (knee)			✓ My best results: (Brain)		
Sampling Rate	PSNR (mean±std)	SSIM (mean±std)	Sampling Rate	PSNR (mean±std)	SSIM (mean±std)
SR=0.1	26.42 ± 2.70	0.731 ± 0.054	SR=0.1	22.77 ± 1.76	0.644 ± 0.050
SR=0.2	32.18 ± 2.97	0.848 ± 0.053	SR=0.2	28.68 ± 2.38	0.828 ± 0.041
SR=0.3	34.31 ± 3.14	0.893 ± 0.044	SR=0.3	32.84 ± 3.08	0.913 ± 0.031
SR=0.5	37.84 ± 3.15	0.939 ± 0.029	SR=0.5	39.30 ± 3.15	0.966 ± 0.015

شکل ۴-۲۵: مقایسه‌ی میانگین دقت روش بنده با بهترین نتایج مقاله برای تصاویر مغز

به طور کلی، امتیازهای تصاویر Brain بنده کمتر شده به این دلیل که من از تصاویر T1-Post استفاده کردم (۱۰۶ تا). همچنین گروه تصاویر T1ی که در مقاله استفاده شده بود، صرفاً ۲۰ تا بود و بعضی از آن تصاویر مشکل داشتند. بنده حتی روی آن سری داده هم روش را تست کردم، گرچه دقت‌ها بیشتر شد اما چون داده‌ها ایراد داشتند، گزارششان نکردم.

فصل چهارم

نتیجه‌گیری و پیشنهادات

۴-۱- نتیجه‌گیری و سخن پایانی

مقاله‌ی جالبی نوشته بودند و بعد از اینکه کدهایش را پیاده‌سازی کردم و توانستم دقت مشابه و حتی بهتر بگیرم، بسیار ذوق کردم! همچنین با اینکه، این مقال در یک مجله‌ی معتبر Q1 چاپ شده بود، اشکالات گرامری و املایی زیادی داشت. همچنین نویسندگانی این مقاله آمدند و روششان را با روش‌های دیگر مقایسه کردند و در همه‌ی نرخ‌های نمونه برداری، روششان بهتر عمل کرده بود، اما آیا داده‌هایشان نیز مشابه بوده؟! برای من سوال است با اینکه این فقط گفتند ما روی ۲۰ تصویر زانو از پایگاه fastMRI مدل را اجرا کردیم، چطوری این مقاله توانسته در چنین مجله‌ی معتبری چاپ شود.

نکته‌ی بعدی این است که من تمایل دارم اگر شما موافق هستید این روش رو ارتقا بدیم و مقاله‌اش کنیم. چون دقتم افزایش پیدا کرده و اگر بتوانیم یک نوآوری بزنیم شاید امکان چاپش وجود داشته باشه. مثلاً دنباله‌ی نزولی سیگما رو به کمک یک adoptive grid search، انتخاب کنیم تا بهینه باشد. چون دقت مدل خیلی به انتخاب دنباله‌ی سیگما بستگی دارد.

همچنین امکان اجرای این مدل روی سایر تصاویر پایگاه fastMRI هم وجود دارد مثل تصاویر سینه یا پروستات.

منابع و مراجع

1. Hassan, E. and A. Ghaffari, *ISRSLO: compressed sensing MRI with image smoothness regularized-smoothed ℓ_0 norm*. Scientific Reports, 2024. **14**(1): p. 24305.
2. Geethanath, S., et al., *Compressed sensing MRI: a review*. Crit Rev Biomed Eng, 2013. **41**(3): p. 183–204.
3. Zaitsev, M., J. Maclaren, and M. Herbst, *Motion artifacts in MRI: A complex problem with many partial solutions*. J Magn Reson Imaging, 2015. **42**(4): p. 887–901.
4. Forrest, W. *New study reveals why many MRI scans are delayed*. 2017; Available from: <https://www.auntminnie.com/clinical-news/mri/article/15617382/new-study-reveals-why-many-mri-scans-are-delayed>.
5. Tavakkoli, M. and M.D. Noseworthy, *A Review on Accelerated Magnetic Resonance Imaging Techniques: Parallel Imaging, Compressed Sensing, and Machine Learning*. Crit Rev Biomed Eng, 2025. **53**(5): p. 71–85.
6. Questions, M. *Isn't parallel imaging (PI) just "regular" MRI using multiple receiver coils?* . 2012; Available from: <https://mriquestions.com/how-is-pi-different.html>.
7. Foti, G. and C. Longo, *Deep learning and AI in reducing magnetic resonance imaging scanning time: advantages and pitfalls in clinical practice*. Polish Journal of Radiology, 2024. **89**: p. 443–451.
8. Questions, M., *What is Fast (Turbo) Spin Echo imaging?* . 2026.
9. Medium. *What is the difference between convex and non-convex cost functions?* 2023; Available from: https://medium.com/@divine_inner_voice/difference-between-convex-and-non-convex-cost-function-what-does-it-mean-when-a-cost-function-is-b781c38663c6.

10. Lebrun, M., *An Analysis and Implementation of the BM3D Image Denoising Method*. Image Processing On Line, 2012. 2: p. 175–213.
11. Documentation, S. *wiener filter in scipy library*. 2026; Available from:
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.signal.wiener.html>.
12. Imperial Colledge London, D.T.S. *Unitary Transforms and the 2D Discrete Fourier Transform*. 2017; Available from:
<https://www.commsp.ee.ic.ac.uk/~tania/teaching/DIP%202014/DIP%20DFT%20Students.pdf>.
13. Wikipedia. *Unitary transformation*. 2025; Available from:
https://en.wikipedia.org/wiki/Unitary_transformation.